De la donnée à la décision

Statistiques pour les Experts Data

Partie 1 — Statistiques descriptives

Modules 0 à 3

Bassem Ben Hamed

bassem.benhamed@enetcom.usf.tn

Formation interne

Plan de la partie 1

Module 0 — Introduction & Cadrage

Module 1 — Décrire une variable

Module 2 — Visualiser une distribution

Module 3 — Relations entre deux variables

Vue d'ensemble de la formation

Architecture de la formation (5 parties, 17 modules)

Partie	Modules
1. Descriptive	M0 Introduction, M1 Décrire une variable, M2 Visualiser une distribution, M3 Relations entre 2 variables
2. Probabilités	M4 Vocabulaire probabiliste, M5 Lois usuelles
3. Inférentielle	M6 Échantillon $\rightarrow$ population, M7 Tests d'hypothèses, M8 Choisir le bon test, M9 Régression linéaire, M10 Régression logistique
4. Séries temporelles	M11 Spécificités, M12 Préparation, M13 Stationnarité & ACF, M14 Modèles (SARIMA, Prophet), M15 Anomalies
5. Synthèse	M16 Communication, M17 Récapitulatif global

Logique pédagogique

Décrire $\rightarrow$ Formaliser l'incertitude $\rightarrow$ Inférer $\rightarrow$ Modéliser dans le temps $\rightarrow$ Communiquer.

Compétences visées en sortie de chaque partie

Partie 1 **Descriptive (M0-M3)** — types de variables, indicateurs adaptés, lire un `describe()`, relation entre 2 variables, pièges classiques (Simpson, causalité).

Partie 2 **Probabilités (M4-M5)** — vocabulaire (variable aléatoire, loi, espérance), lois usuelles (Bernoulli, binomiale, Poisson, normale, log-normale, exponentielle), notion d'odds.

Partie 3 **Inférentielle (M6-M10)** — intervalle de confiance, test d'hypothèse, choix du test adapté, régression linéaire et logistique.

Partie 4 **Séries temporelles (M11-M15)** — décomposition, stationnarité, SARIMA et Prophet, validation en split temporel, détection d'anomalies.

Partie 5 **Synthèse (M16-M17)** — présenter une analyse à un public technique *ou* business, choisir l'outil adapté à la question.

Module 0 — Introduction & Cadrage

Objectifs du module 0

- Distinguer statistique descriptive, inférentielle et séries temporelles.
- Comprendre le rôle d'un **data analyst** dans un workflow statistique.
- Identifier le bon outil pour la bonne question business.

Fil rouge

Une donnée brute ne dit rien. Les statistiques sont l'outil qui transforme une question business en réponse *quantifiée et défendable*.

Pourquoi les statistiques pour un data analyst ?

Cas d'usage typiques

- Reporting : KPI fiable + marge d'erreur.
- A/B testing : conclure une expérimentation.
- Prévision : ventes, trafic, stocks.
- Détection d'anomalies.
- Comprendre une relation entre variables.

Sans stats, on tombe dans :

- « La moyenne a baissé de 2% »
  $\rightarrow$ est-ce significatif ?
- « Les ventes sont en hausse »
  $\rightarrow$ tendance ou saisonnalité ?
- « X cause Y »
  $\rightarrow$ ou variable confondante ?

Trois grandes familles d'outils

Descriptive
Résumer ce qu'on a

Inférentielle
Généraliser à la population

Séries temporelles
Comprendre & prévoir le temps

- **Descriptive** : « À quoi ressemblent mes ventes du Q1 ? »
- **Inférentielle** : « La nouvelle version convertit-elle mieux ? »
- **Séries temporelles** : « Combien va-t-on vendre en juin ? »

Vocabulaire et notations

Quatre mots à ne jamais confondre

Population L'ensemble complet qu'on étudie. Taille N.

Échantillon Le sous-ensemble réellement observé. Taille n.

Paramètre Vraie valeur *inconnue* dans la population.

Estimation Calculée à partir de l'échantillon.

Quantité	Paramètre (population)	Estimation (échantillon)
Moyenne	μ	$\bar{x}$
Variance	σ^2	s^2
Écart-type	σ	s
Proportion	p	$\hat{p}$

Types de variables

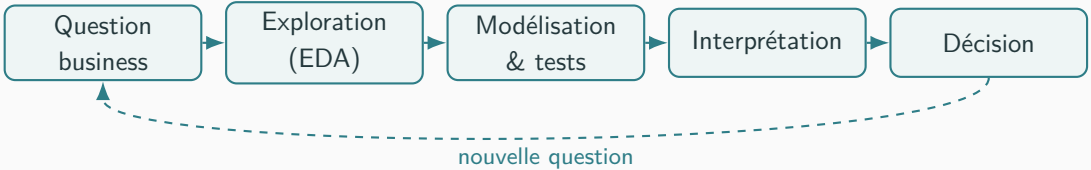
Famille	Sous-type	Exemple pharma
Qualitative	Nominale	Catégorie ATC (M01AB, R06…)
Qualitative	Ordinale	Sévérité (faible / moyen / fort)
Quantitative	Discrète	Nombre de boîtes vendues
Quantitative	Continue	Prix, durée d'effet

Conséquence directe

Le type de variable **détermine** les indicateurs et tests utilisables.

On ne calcule pas une moyenne sur une catégorie ATC ; on ne fait pas un χ^2 sur des prix.

Le cycle d'une analyse



Erreur classique : sauter directement à la modélisation sans exploration → on modélise du bruit.

À retenir — Module 0

Trois réflexes à acquérir

1. Avant tout calcul, identifier le **type** de chaque variable.
2. Toujours distinguer ce qu'on **observe** (échantillon) de ce qu'on **estime** (population).
3. Choisir l'outil selon la **question**, pas l'inverse.

Module 1 — Décrire une variable

Objectifs du module 1

- Choisir les bons indicateurs selon le type de variable.
- Comprendre les **formules** de chaque indicateur, et pourquoi elles sont définies ainsi.
- Lire un `df.describe()` avec un œil critique.

Tendance centrale — la moyenne

Formule

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Lecture composant par composant :

- $\sum_{i=1}^{n} x_i$: somme de toutes les valeurs.
- $\frac{1}{n}$: on divise par le nombre d'observations.
- Chaque x_i pèse exactement de la même façon $(1/n)$.

Conséquence directe

Comme *toutes les valeurs ont le même poids*, une seule valeur extrême peut tirer fortement la moyenne. C'est ce qui rend la moyenne **sensible aux outliers**.

Tendance centrale — médiane et mode

Médiane

Valeur $\tilde{x}$ telle que 50% des observations sont $\leq \tilde{x}$ et 50% sont $\geq \tilde{x}$.

$$\tilde{x} = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & \text{si } n \text{ impair} \\ \dfrac{x_{(n/2)} + x_{(n/2+1)}}{2} & \text{si } n \text{ pair} \end{cases}$$

où $x_{(i)}$ désigne la i-ème valeur *après tri croissant*.

Pourquoi elle résiste aux outliers : on n'utilise que le *rang*, pas la valeur. Un outlier de 800 ou 8000 ne change rien à la position du milieu. **Mode :** valeur la plus fréquente. Seul indicateur de centralité utilisable sur les variables **qualitatives**.

Moyenne ou médiane ? L'exemple qui fâche

Cas pratique : ventes journalières d'antalgiques (N02BE)

- 9 jours de ventes : 30, 32, 35, 38, 40, 42, 45, 48, 50
- 1 jour exceptionnel (rappel d'un concurrent) : 800

$\bar{x} = 116$ vs médiane $= 41$

- La **moyenne** est tirée par l'outlier $\rightarrow$ trompeuse pour décrire un jour « typique ».
- La **médiane** reste robuste $\rightarrow$ meilleur indicateur du jour normal.

Règle : distribution asymétrique ou outliers $\Rightarrow$ préférer la médiane.

Dispersion — variance et écart-type

Formules

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 \quad \text{(variance échantillonnale)}$$

$$s = \sqrt{s^2} \quad \text{(écart-type)}$$

Lecture composant par composant :

- $(x_i - \bar{x})$ **:** écart de chaque point au centre.
- **Le carré :** les écarts $\pm$ ne s'annulent pas, et les grands écarts sont davantage pénalisés.
- $n-1$ **et pas** n **:** on a « consommé » une info en estimant $\bar{x}$; corrige le biais (*correction de Bessel*).
- $s = \sqrt{s^2}$ **:** pour revenir à l'*unité d'origine*.

Dispersion — IQR et coefficient de variation

Étendue interquartile (IQR)

$$\mathrm{IQR} = Q_3 - Q_1$$

où Q_1 = quartile inférieur (P25), Q_3 = quartile supérieur (P75). Mesure la largeur des 50% centraux. Robuste aux outliers.

Coefficient de variation (CV)

$$\mathrm{CV} = \frac{s}{\bar{x}}$$

Sans dimension (souvent exprimé en %). Permet de comparer la dispersion entre deux variables d'*unités différentes*.

Cas pharma : comparer la variabilité du nombre de boîtes vendues (CV $\approx 0{,}3$) à celle des prix (CV $\approx 0{,}05$) : les prix sont beaucoup plus stables *en relatif*.

Quand utiliser quoi ?

Situation	Indicateur recommandé
Distribution normale ou symétrique	Moyenne $\bar{x}$ + écart-type s
Distribution asymétrique, outliers	Médiane $\tilde{x}$ + IQR
Comparer la dispersion entre 2 unités	Coefficient de variation (CV)
Détecter les valeurs atypiques	IQR + boxplot

Piège classique

Reporter *seulement* la moyenne dans un dashboard sans la dispersion masque toute la variabilité du métier.

Forme — skewness (asymétrie)

Formule

$$g_1 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s}\right)^3$$

Pourquoi ça marche :

- On centre et réduit chaque écart : $\frac{x_i - \bar{x}}{s}$ — sans dimension, comparable.
- On élève au cube : puissance *impaire* $\rightarrow$ préserve le signe (écarts à droite : contributions $+$; à gauche : $-$).

Lecture :

- $g_1 \approx 0$: symétrique.
- $g_1 > 0$: queue à droite (salaires, prix), $\bar{x} > \tilde{x}$.
- $g_1 < 0$: queue à gauche, $\bar{x} < \tilde{x}$.

Forme — kurtosis (aplatissement)

Formule (excess kurtosis)

$$g_2 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s}\right)^4 - 3$$

Le -3 centre la kurtosis sur **0 pour une loi normale**.

Pourquoi la puissance 4 : toujours positive (additivement informative) et amplifie *très fortement* les valeurs extrêmes — précisément ce qu'on veut détecter.

Lecture business

- $g_2 > 0$ (queues lourdes) : événements rares plus fréquents qu'attendu → plans de contingence.
- $g_2 < 0$ (queues fines) : valeurs concentrées autour du centre.

Cas pharma : effets indésirables, ruptures de stock, pics de demande → surveiller la kurtosis.

Quantiles, percentiles et boxplot

Définition

Le quantile d'ordre $q \in [0,1]$, noté $Q(q)$, est la valeur telle que $\mathbb{P}(X \leq Q(q)) = q$.
Médiane $= Q(0{,}5)$, $Q_1 = Q(0{,}25)$, $Q_3 = Q(0{,}75)$, $P_{95} = Q(0{,}95)$.

Anatomie d'un boxplot :

- Boîte : de Q_1 à Q_3 (les 50% centraux) ; trait au milieu : médiane.
- Moustaches : jusqu'à $1{,}5 \times \mathrm{IQR}$ au-delà des quartiles.
- Points isolés au-delà : outliers potentiels.

Règle de Tukey : x_i outlier si $x_i < Q_1 - 1{,}5 \cdot \mathrm{IQR}$ ou $x_i > Q_3 + 1{,}5 \cdot \mathrm{IQR}$.

Lire un `describe()` comme un pro

	N02BE	R06	N05B	R03
count	2106	2106	2106	2106
mean ($\bar{x}$)	78.2	12.4	19.8	15.1
std (s)	24.5	11.8	8.2	9.6
min	12.0	0.0	1.0	0.0
25% (Q_1)	60.0	4.0	14.0	8.0
50% ($\tilde{x}$)	76.0	9.0	19.0	14.0
75% (Q_3)	95.0	17.0	25.0	20.0
max	220.0	95.0	58.0	65.0

- **R06** : $\bar{x} > \tilde{x}$ et max très élevé $\rightarrow$ skewness > 0 (pics saisonniers).
- **N02BE** : $\mathrm{CV} = 24{,}5/78{,}2 \approx 0{,}31$. Distribution plutôt régulière.
- **N05B / R03** : moyennes proches mais IQR différents $\rightarrow$ dispersions différentes.

Pièges courants — Module 1

Ne pas tomber dedans

1. Comparer des moyennes sans regarder la dispersion ni la taille des groupes.
2. Utiliser la moyenne sur une distribution clairement asymétrique.
3. Confondre **0** (vraie valeur) et **NaN** (donnée manquante) — surtout en pharma : « 0 vente » vs « pharmacie fermée ».
4. Reporter une statistique sans son unité.
5. Calculer une moyenne sur une variable ordinale (« satisfaction moyenne = 3,4 » sur une échelle de Likert).

À retenir — Module 1

Le réflexe à 5 chiffres

Pour décrire une variable quantitative, ne jamais se contenter d'un seul indicateur.

Regarder *au minimum* :

n	$\bar{x} \mid \tilde{x}$	$s \mid \mathrm{IQR}$	min	max

Et un **boxplot** ou un **histogramme** pour confirmer la forme.

Module 2 — Visualiser une distribution

Objectifs du module 2

- Choisir la bonne visualisation selon la question.
- Reconnaître les distributions classiques à l'œil et par leur **formule**.
- Comprendre l'impact des choix de paramètres (bins, échelle).

Quelle visualisation pour quelle question ?

Question	Visualisation
Forme générale d'une distribution	Histogramme, KDE
Comparer plusieurs groupes	Boxplots côte à côte, violin plots
Détecter outliers & asymétrie	Boxplot
Voir densité *et* valeurs	Violin plot, strip plot
Distribution cumulée (P95, P99)	ECDF (courbe cumulative)

Histogramme : choix du nombre de bins

Deux règles classiques

Sturges $k = 1 + \log_2(n)$ — simple, mais sous-estime k pour les grands n.

Freedman-Diaconis $h = 2 \cdot \dfrac{\mathrm{IQR}}{n^{1/3}}$

avec h = largeur d'un bin, $k = (\max - \min)/h$. Robuste aux outliers (utilise IQR).

Conseil pratique :

- Trop peu de bins $\rightarrow$ on lisse, on rate les modes.
- Trop de bins $\rightarrow$ on voit du bruit.
- En complément : **KDE** (kernel density estimation) — moins sensible aux bins.

Loi normale (gaussienne)

Densité de probabilité

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Notation : $X \sim \mathcal{N}(\mu, \sigma^2)$.

Lecture :

- μ : centre de la cloche (moyenne = médiane = mode).
- σ : largeur — plus σ est grand, plus la cloche est étalée.
- L'exponentielle décroît très vite $\rightarrow$ valeurs loin du centre rares.

Règle des 68-95-99,7 (« règle empirique »)

$$\mathbb{P}(|X-\mu| \leq \sigma) \approx 68\%, \quad \mathbb{P}(|X-\mu| \leq 2\sigma) \approx 95\%, \quad \mathbb{P}(|X-\mu| \leq 3\sigma) \approx 99{,}7\%.$$

Loi log-normale

Définition

X suit une loi log-normale si $\ln(X) \sim \mathcal{N}(\mu, \sigma^2)$.

$$f(x) = \frac{1}{x\,\sigma\sqrt{2\pi}}\,\exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0$$

Lecture :

- Toujours **positive**, asymétrique à droite.
- Apparaît dès que la grandeur résulte d'un *produit* de petits effets aléatoires.
- En *échelle log*, redevient symétrique (gaussienne).

Cas typiques : prix, revenus, durée de session web, temps de réponse serveur, dosages.

Loi de Poisson

Loi de probabilité (variable discrète)

$$\mathbb{P}(X = k) = \frac{\lambda^k \, e^{-\lambda}}{k!}, \quad k \in \{0, 1, 2, \dots\}$$

Propriété remarquable : $\mathbb{E}[X] = \mathrm{Var}(X) = \lambda$.

Lecture :

- λ : nombre moyen d'événements par unité de temps/espace.
- Modélise des événements *rares*, *indépendants*, à *taux constant*.
- Si moyenne $\approx$ variance dans vos données $\rightarrow$ Poisson est plausible.

Cas pharma : nombre d'effets indésirables par jour, appels SAV par heure, ruptures par mois, prescriptions d'un médicament rare.

Loi binomiale

Loi de probabilité (variable discrète)

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, 1, \ldots, n\}$$

$$\mathbb{E}[X] = np, \qquad \mathrm{Var}(X) = np(1-p)$$

Lecture :

- n : nombre d'essais indépendants ; p : probabilité de succès à chaque essai.
- $\binom{n}{k}$: nombre de façons de choisir k succès parmi n essais.
- Quand n devient grand, la binomiale tend vers une normale (théorème de Moivre-Laplace).

Cas pharma : nombre de patients répondant à un traitement sur 100, taux de conversion d'une campagne, qualité d'un lot.

Échelle log : votre meilleure amie

Quand une variable s'étale sur plusieurs ordres de grandeur (prix, durées, populations), une **échelle logarithmique** révèle la structure que l'échelle linéaire écrase.

- Distribution log-normale $\rightarrow$ **symétrique** en log.
- Croissance exponentielle $\rightarrow$ **linéaire** en log.
- Multiplications $\rightarrow$ additions visuelles.

Cas pharma

Le nombre d'unités vendues d'un médicament en rupture concurrente peut passer de 5 à 5000 en quelques jours. Sur échelle linéaire, on ne voit que le pic ; en log, on voit la *dynamique* (vitesse de remontée).

À retenir — Module 2

Trois réflexes visuels

1. Toujours **tracer la distribution** avant de calculer un test.
2. Si les données s'étalent sur plusieurs ordres de grandeur $\rightarrow$ tester l'**échelle log**.
3. La **forme** (normale, log-normale, Poisson…) détermine les outils utilisables ensuite (paramétrique vs non paramétrique).

Module 3 — Relations entre deux variables

Objectifs du module 3

- Mesurer et visualiser une relation selon les types de variables.
- Maîtriser les formules de Pearson, Spearman, χ^2, V de Cramér, η^2.
- Distinguer fermement **corrélation** et **causalité**.

Trois cas selon les types de variables

X \ Y	**Quantitative**	**Qualitative**
Quantitative	Scatter + Pearson / Spearman	Boxplots, η^2
Qualitative	Boxplots, η^2	Contingence + χ^2, V de Cramér

Chaque case appelle un outil différent. **Identifier les types est la première étape.**

Quanti-Quanti — covariance

Définition

$$\mathrm{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

Comment la lire :

- Pour chaque observation, on regarde si x_i et y_i sont *du même côté* de leurs moyennes.
- Mêmes côtés (les deux > 0 ou les deux < 0) $\rightarrow$ produit positif.
- Côtés opposés $\rightarrow$ produit négatif.
- La somme dit si la tendance globale est concordante ou opposée.

Limite : la covariance dépend des unités (€ $\times$ kg, °C $\times$ min...) $\rightarrow$ pas comparable d'une paire à l'autre. D'où Pearson.

Quanti-Quanti — coefficient de Pearson

Formule

$$r = \frac{\mathrm{Cov}(X,Y)}{s_X \cdot s_Y} = \frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i-\bar{y})^2}}$$

Pourquoi cette définition :

- On divise la covariance par le produit des écarts-types $\rightarrow$ on *normalise*.
- Le résultat est borné : $r \in [-1,+1]$, sans unité.
- $r=+1$: tous les points alignés sur une droite croissante. $r=-1$: décroissante. $r=0$: pas de relation *linéaire*.

Repères pratiques : $|r|>0{,}7$ fort ; $0{,}3<|r|<0{,}7$ modéré ; $|r|<0{,}3$ faible.

Quanti-Quanti — coefficient de Spearman

Formule (sans ex æquo)

$$\rho = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n(n^2 - 1)}$$

où $d_i = \mathrm{rg}(x_i) - \mathrm{rg}(y_i)$ est la différence de **rangs**.

Pourquoi sur les rangs :

- On remplace chaque valeur par sa position dans le tri $\rightarrow$ insensible aux échelles et aux outliers.
- Détecte les relations **monotones**, pas seulement linéaires (exponentielles, logarithmiques...).
- Spearman = Pearson appliqué aux rangs.

Quand préférer Spearman : outliers, distribution asymétrique, ou relation visiblement non linéaire mais monotone.

Toujours commencer par un nuage de points

Un coefficient seul peut être trompeur. Le célèbre *quartet d'Anscombe* : 4 jeux de données avec r identique mais des formes radicalement différentes.

- Relation linéaire propre.
- Relation parabolique (Pearson manque tout).
- Linéaire avec un outlier qui domine.
- Pas de relation, mais un point isolé crée le coefficient.

Règle absolue : visualiser avant de quantifier.

Quali-Quanti — décomposition de la variance

Pour comparer une variable quantitative entre g groupes, on décompose la variabilité totale :

Identité fondamentale

$$\underbrace{\sum_i (x_i - \bar{x})^2}_{SS_{\text{total}}} = \underbrace{\sum_g n_g (\bar{x}_g - \bar{x})^2}_{SS_{\text{inter}}} + \underbrace{\sum_g \sum_{i \in g} (x_i - \bar{x}_g)^2}_{SS_{\text{intra}}}$$

Lecture :

- SS_{inter} : variabilité *entre* groupes (moyennes différentes).
- SS_{intra} : variabilité *à l'intérieur* de chaque groupe.
- Si SS_{inter} domine $\rightarrow$ les groupes diffèrent vraiment.

Quali-Quanti — coefficient η^2

Formule

$$\eta^2 = \frac{SS_{\text{inter}}}{SS_{\text{total}}} \in [0, 1]$$

Lecture : proportion de la variance *expliquée* par l'appartenance au groupe.

Repères pratiques

- $\eta^2 < 0{,}01$: effet négligeable.
- $0{,}01 \leq \eta^2 < 0{,}06$: effet faible.
- $0{,}06 \leq \eta^2 < 0{,}14$: effet moyen.
- $\eta^2 \geq 0{,}14$: effet fort.

Cas pharma : ventes par jour de la semaine $\rightarrow \eta^2 \approx 0{,}18$: l'effet jour est *fort*.

Quali-Quali — tableau de contingence et χ^2

Tableau croisé entre deux variables qualitatives. On compare les effectifs **observés** O_{ij} aux **attendus en cas d'indépendance** E_{ij} :

$$E_{ij} = \frac{n_{i\cdot} \times n_{\cdot j}}{n} \quad \text{(produit des marges, divisé par le total)}$$

Statistique du chi-deux

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Lecture :

- Chaque case mesure l'écart à l'indépendance, normalisé par l'attendu.
- Plus χ^2 est grand, plus les variables sont *associées*.
- Limite : valeur dépendante de n et de la taille du tableau $\rightarrow$ non comparable.

Quali-Quali — V de Cramér

Formule

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(r-1, c-1)}} \in [0, 1]$$

avec r = nombre de lignes, c = nombre de colonnes du tableau.

Pourquoi cette définition :

- Normalise χ^2 par la taille de l'échantillon n et la *plus petite dimension* du tableau.
- Borne le résultat dans $[0, 1]$, comparable entre tableaux de tailles différentes.

Repères pratiques

- $V < 0{,}1$: association négligeable.
- $0{,}1 \leq V < 0{,}3$: faible. $0{,}3 \leq V < 0{,}5$: modérée. $V \geq 0{,}5$: forte.

Quali-Quali — exemple pharma

Catégorie ATC × saison du pic

	Hiver	Printemps	Été	Automne
R06 (antihistaminiques)	12%	**48%**	28%	12%
N02BE (paracétamol)	**38%**	22%	15%	25%
R03 (asthme)	22%	18%	12%	**48%**

Lecture : forte structure saisonnière par catégorie. Un calcul donne χ^2 élevé et $V \approx 0{,}45 \rightarrow$ **association modérée à forte**.

Matrice de corrélation

Pratique pour balayer rapidement *toutes* les paires de variables quantitatives.

- Visualisée en **heatmap** (`sns.heatmap` avec annotations).
- Permet de repérer des groupes de variables corrélées.
- Utile avant une régression : détecter la multicolinéarité.

Limites

- Ne capture que les relations linéaires (Pearson) ou monotones (Spearman).
- Avec beaucoup de variables : si on teste k corrélations, on attend $\approx 0{,}05k$ « significatives » par pur hasard. Penser à corriger (Bonferroni, Benjamini-Hochberg).

Corrélation $\neq$ causalité

Exemples qui font sourire

- Ventes de glaces et noyades $\rightarrow$ corrélées (variable cachée : la chaleur).
- Taille des pieds et niveau de lecture chez les enfants (variable cachée : l'âge).
- Consommation de chocolat par pays et nombre de prix Nobel.

Quatre explications possibles d'une corrélation :

1. X cause Y.
2. Y cause X (causalité inverse).
3. Une troisième variable Z cause les deux (*confondante*).
4. Pure coïncidence (surtout avec beaucoup de variables testées).

Pour conclure à la causalité : **expérimentation contrôlée** ou méthodes causales avancées.

Le paradoxe de Simpson

Définition : une tendance observée dans plusieurs groupes peut s'inverser lorsqu'on agrège les groupes.

Cas classique en pharma

- Traitement A : taux de guérison **global** $= 78\%$
- Traitement B : taux de guérison **global** $= 83\%$

Mais en stratifiant par sévérité (faible vs forte) :

- Cas *légers* : A $= 93\%$, B $= 87\%$.
- Cas *sévères* : A $= 73\%$, B $= 69\%$.

A est **meilleur dans chaque sous-groupe**, mais perd dans l'agrégat car il a été davantage donné aux cas sévères.

Pièges courants — Module 3

Ne pas tomber dedans

1. Calculer un Pearson sans tracer le scatter plot.
2. Conclure « pas de relation » parce que $r \approx 0$ (la relation peut être non linéaire).
3. Confondre corrélation et causalité dans une présentation business.
4. Oublier les variables confondantes (Simpson).
5. Multiplier les corrélations sans correction (faux positifs).

À retenir — Module 3

Cinq questions à se poser face à une corrélation

1. Ai-je tracé le **scatter** ?
2. La relation est-elle **linéaire** ou **monotone** ?
3. Y a-t-il des **outliers** qui dominent le coefficient ?
4. Existe-t-il une **variable confondante** plausible ?
5. Ai-je segmenté pour vérifier l'absence de **Simpson** ?

Synthèse de la partie 1

Ce que vous savez faire à la fin de la partie 1

- Identifier les types de variables et choisir les indicateurs adaptés.
- Calculer et interpréter moyenne, médiane, variance, écart-type, IQR, CV, skewness, kurtosis.
- Reconnaître les distributions classiques (normale, log-normale, Poisson, binomiale) à leur formule et à leur forme.
- Mesurer la relation entre deux variables avec l'outil adapté à leurs types.
- Lire et interpréter Pearson, Spearman, η^2, χ^2 et V de Cramér.
- Éviter les pièges fondamentaux (causalité, Simpson, outliers).

Suite de la formation

Partie 2 — Probabilités (M4-M5)

Vocabulaire probabiliste, lois usuelles, notion d'odds — le pont entre statistique descriptive et inférence.

Partie 3 — Statistiques inférentielles (M6-M10)

Du descriptif à la décision : intervalles de confiance, tests d'hypothèses, régression linéaire et logistique.

Partie 4 — Séries temporelles (M11-M15)

Décomposition, stationnarité, SARIMA, Prophet, détection d'anomalies.

Partie 5 — Synthèse (M16-M17)

Communication des résultats et arbre de décision global.

Questions ?

Pause avant la partie probabilités

Bassem Ben Hamed — bassem.benhamed@enetcom.usf.tn