De la donnée à la décision

Statistiques pour les Experts Data

Partie 2 — Notions de probabilités utiles

Modules 4 et 5

Bassem Ben Hamed

bassem.benhamed@enetcom.usf.tn

Formation interne

Plan de la partie 2

Module 4 — Le minimum vital pour un analyst

Module 5 — Lois de probabilité usuelles

Où en sommes-nous ?

Architecture de la formation (5 parties, 17 modules)

Partie	Modules
1. Descriptive	M0 Introduction, M1 Décrire une variable, M2 Visualiser, M3 Relations
2. Probabilités	**M4 Vocabulaire probabiliste, M5 Lois usuelles**
3. Inférentielle	M6 Échantillon $\rightarrow$ population, M7 Tests d'hypothèses, M8 Choisir le bon test, M9 Régression linéaire, M10 Régression logistique
4. Séries temporelles	M11 Spécificités, M12 Préparation, M13 Stationnarité, M14 SARIMA & Prophet, M15 Anomalies
5. Synthèse	M16 Communication, M17 Récapitulatif global

Pourquoi insérer les probabilités ici ?

Sans elles, l'inférence (Partie 3) repose sur des incantations. Cette partie 2 est le **pont** entre « décrire ce qu'on a » (Partie 1) et « généraliser à partir d'un échantillon » (Partie 3).

Pourquoi un data analyst doit comprendre les probabilités

À quoi ça sert dans la pratique

- Lire correctement une *p-value*.
- Comprendre un *intervalle de confiance*.
- Choisir une *loi de référence* pour un test.
- Lire une *régression logistique* (odds).
- Quantifier un *stock de sécurité*.
- Interpréter un *intervalle de prédiction* (forecast).

Sans elles, on lit du bruit

- « $p < 0{,}05$ donc l'effet est important » (faux).
- « 95 % de chances que la vraie moyenne soit ici » (faux).
- « La normale s'applique partout » (faux).
- « OR $= 2$ doublera mes ventes » (faux).

Module 4 — Le minimum vital pour un analyst

Objectifs du module 4

- Acquérir le vocabulaire probabiliste indispensable à la lecture des modules suivants.
- Comprendre intuitivement variable aléatoire, loi de probabilité, espérance, variance.
- Faire le pont entre la **statistique descriptive** (M1) et l'**inférence** (M6).

Principe pédagogique

On vise l'**intuition** et la **lecture** des résultats. Pas de démonstration formelle.

Vocabulaire de base

Quatre objets fondamentaux

Expérience aléatoire Phénomène dont l'issue est incertaine. Ex : un patient répond-il au traitement ?

Univers Ω Ensemble de tous les résultats possibles. Ex : $\Omega = \{\text{succès}, \text{échec}\}$.

Événement Sous-ensemble de Ω. Ex : $A =$ « le patient répond ».

Probabilité $\mathbb{P}(A)$ Nombre dans $[0, 1]$ qui mesure la « vraisemblance » de A.

Trois axiomes de Kolmogorov :

1. $0 \leq \mathbb{P}(A) \leq 1$
2. $\mathbb{P}(\Omega) = 1$ (un résultat se produit forcément)
3. Si $A \cap B = \emptyset$: $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$ (additivité)

Interprétation fréquentiste de la probabilité

Définition

$$\mathbb{P}(A) = \lim_{n \to \infty} \frac{n_A}{n}$$

où n_A est le nombre de fois où A se produit sur n répétitions de l'expérience.

Lecture intuitive :

- « La probabilité, c'est la fréquence relative *à long terme*. »
- Plus on répète, plus la fréquence observée se rapproche de la « vraie » probabilité.
- C'est cette interprétation que vous croiserez dans 99 % des cas business.

Cas pharma

« 12 % des patients sous traitement A développent un effet indésirable » signifie : sur un grand nombre de patients, la fréquence d'effets indésirables tend vers 0,12.

Règles de calcul élémentaires

Trois identités à connaître

$$\mathbb{P}(\bar{A}) = 1 - \mathbb{P}(A) \qquad \text{(événement contraire)}$$

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \qquad \text{(union)}$$

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B \mid A) \qquad \text{(intersection)}$$

Lecture :

- **Contraire :** la somme des deux possibilités vaut 1.
- **Union :** si on additionnait simplement, on compterait deux fois l'intersection — d'où la soustraction.
- **Intersection :** la probabilité que A et B se produisent = probabilité de A, fois probabilité de B *sachant que A est arrivé*.

Probabilité conditionnelle

Définition

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}, \quad \mathbb{P}(B) > 0$$

Lecture composant par composant :

- « Probabilité de A *sachant que* B s'est produit. »
- On réduit l'univers à B : seuls les cas où B est vrai comptent.
- Numérateur : cas où A *et* B sont vrais. Dénominateur : cas où B est vrai (nouvelle base).

Pourquoi c'est central pour l'analyst

La **p-value** (Module 7) est une probabilité conditionnelle :

$$p = \mathbb{P}(\text{observer cet effet ou plus} \mid H_0 \text{ vraie})$$

Indépendance

Définition

Deux événements A et B sont **indépendants** si :

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

De manière équivalente : $\mathbb{P}(A \mid B) = \mathbb{P}(A)$.

Lecture :

- « Savoir que B est arrivé ne change rien à la probabilité de A. »
- C'est une hypothèse forte et souvent fausse en pratique.

Cas pharma

Les ventes d'antalgiques (N02BE) et d'AINS (M01AB) sont **corrélées** (cf. Module 3). Donc *pas* indépendantes : connaître une grosse vente de N02BE rend plus probable une grosse vente de M01AB le même jour.

Théorème de Bayes

Formule

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(B \mid A) \cdot \mathbb{P}(A)}{\mathbb{P}(B)}$$

Lecture :

- Permet de retourner une probabilité conditionnelle.
- Vocabulaire : $\mathbb{P}(A)$ *a priori*, $\mathbb{P}(A \mid B)$ *a posteriori*.
- $\mathbb{P}(B \mid A)$: « vraisemblance ».

Pourquoi c'est crucial

Un test diagnostic à 99 % de sensibilité ne donne **pas** 99 % de chances d'être malade en cas de positif — tout dépend de la prévalence *a priori* de la maladie.

Cas pratique : test de dépistage

Données

- Prévalence de la maladie : $\mathbb{P}(M) = 1\,\% = 0{,}01$.
- Sensibilité (vrai positif) : $\mathbb{P}(T^+ \mid M) = 99\,\%$.
- Spécificité (vrai négatif) : $\mathbb{P}(T^- \mid \bar{M}) = 95\,\%$, donc $\mathbb{P}(T^+ \mid \bar{M}) = 5\,\%$.

Question : si le test est positif, quelle est la probabilité d'être malade ?

$$\begin{aligned}\mathbb{P}(M \mid T^+) &= \frac{\mathbb{P}(T^+ \mid M) \cdot \mathbb{P}(M)}{\mathbb{P}(T^+)} \\ &= \frac{0{,}99 \times 0{,}01}{0{,}99 \times 0{,}01 + 0{,}05 \times 0{,}99} \approx 16{,}7\,\%\end{aligned}$$

Contre-intuitif : un test très précis sur une maladie rare donne beaucoup de **faux positifs**. C'est l'erreur classique en santé, en détection de fraude, etc.

Variable aléatoire

Définition intuitive

Une **variable aléatoire** X associe un *nombre* à chaque résultat de l'expérience.

$$X : \Omega \longrightarrow \mathbb{R}$$

C'est le pont central de la formation :

- **Descriptif (Partie 1)** : on observait des données concrètes $(x_1, \ldots, x_n)$.
- **Probabilités** : on modélise le *phénomène qui les a générées* comme une v.a. X.
- **Inférence (Partie 3)** : les données servent à estimer les paramètres de X.

Cas pharma

$X =$ « ventes journalières de N02BE ». Chaque jour, X prend une valeur (par ex. 32 unités). Sur 6 ans on a 2 100 réalisations de X.

Variables discrètes vs continues

	Discrète	**Continue**
Valeurs prises	$\{0, 1, 2, 3, \dots\}$	Tout intervalle de $\mathbb{R}$
Loi décrite par	PMF $\mathbb{P}(X = k)$	Densité $f(x)$
Calcul de proba	Somme	Intégrale
Exemple pharma	Effets indésirables / jour	Temps de réponse, dosage en mg

Subtilité importante (continue)

Pour une v.a. continue : $\mathbb{P}(X = x) = 0$ pour toute valeur précise. Seuls les **intervalles** ont une probabilité non nulle : $\mathbb{P}(a \leq X \leq b) = \int_a^b f(x)\,\mathrm{d}x$.

Loi de probabilité — cas discret (PMF)

Fonction de masse (PMF)

$$p_X(k) = \mathbb{P}(X = k) \quad \text{pour } k \in \{0, 1, 2, \dots\}$$

avec deux contraintes :

$$p_X(k) \geq 0, \qquad \sum_k p_X(k) = 1$$

Lecture :

- Chaque barre du graphique vaut une probabilité.
- La somme de toutes les barres vaut exactement 1.
- Pour calculer $\mathbb{P}(a \leq X \leq b)$: on *somme* les barres entre a et b.

Loi de probabilité — cas continu (PDF)

Fonction de densité (PDF)

$$f_X(x) \quad \text{tel que} \quad f_X(x) \geq 0 \ \text{ et } \ \int_{-\infty}^{+\infty} f_X(x)\,\mathrm{d}x = 1$$

Lecture composant par composant :

- $f_X(x)$ n'est pas une probabilité — c'est une *densité* (proba par unité de x).
- L'*aire sous la courbe* entre a et b donne $\mathbb{P}(a \leq X \leq b)$.
- L'aire totale vaut 1.

Erreur fréquente

Lire un point de la PDF comme une probabilité. $f(x_0) = 2$ ne signifie *pas* « probabilité 2 » (impossible) : c'est juste une densité élevée localement.

Fonction de répartition (CDF)

Définition

$$F_X(x) = \mathbb{P}(X \leq x)$$

Toujours croissante de 0 à 1.

Pourquoi c'est utile pour un analyst :

- Lecture directe d'une probabilité cumulée : « au plus 30 ventes / jour ».
- Sa réciproque $F_X^{-1}(q)$ donne le **quantile** d'ordre q (cf. Module 1).
- Les **p-values** sont lues sur la CDF de la loi de référence.

Lien avec PMF / PDF :

- Discret : $F_X(x) = \sum_{k \leq x} \mathbb{P}(X = k)$.
- Continu : $F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t$, et $f_X(x) = F_X'(x)$.

Espérance d'une variable aléatoire

Formules

$$\mathbb{E}[X] = \sum_k k \cdot \mathbb{P}(X = k) \qquad \text{(discret)}$$

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x \cdot f_X(x)\,\mathrm{d}x \qquad \text{(continu)}$$

Lecture :

- « Valeur moyenne attendue à long terme. » Chaque x est pondérée par la *probabilité* de l'observer.
- Version théorique de la moyenne empirique $\bar{x}$ du Module 1.

Loi des grands nombres

Quand $n \to \infty$: $\bar{x}_n \longrightarrow \mathbb{E}[X]$. C'est ce qui justifie d'*estimer* $\mathbb{E}[X]$ par $\bar{x}$.

Variance d'une variable aléatoire

Formule

$$\mathrm{Var}(X) = \mathbb{E}\big[(X - \mathbb{E}[X])^2\big] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Et l'écart-type : $\sigma_X = \sqrt{\mathrm{Var}(X)}$.

Lecture : espérance des écarts au carré au centre — version théorique de la variance empirique du Module 1. Plus $\mathrm{Var}(X)$ est grande, plus la variable est *dispersée*. **Trois propriétés à connaître :**

- $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$
- $\mathrm{Var}(aX + b) = a^2\mathrm{Var}(X)$ (le b disparaît)
- Si X et Y *indépendantes* : $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$.

Pont statistique $\leftrightarrow$ probabilité

	Statistique (M1) *ce qu'on a observé*	**Probabilité (M4)** *ce qui les a générés*
Centre	$\bar{x}$	$\mathbb{E}[X] = \mu$
Dispersion	s, s^2	σ, σ^2
Distribution	histogramme	PMF / PDF
Cumul	ECDF empirique	CDF F_X

À retenir

Une **statistique** décrit ce qu'on a observé. Une **probabilité** décrit ce qu'on s'attendrait à observer si on répétait l'expérience. L'**inférence** (Partie 3) est le pont entre les deux.

À retenir — Module 4

Cinq concepts à maîtriser

1. Probabilité conditionnelle $\mathbb{P}(A \mid B)$ — la base de la lecture des p-values.
2. Bayes — pourquoi un test précis donne des faux positifs sur des événements rares.
3. Variable aléatoire — le modèle théorique derrière les données.
4. PMF / PDF / CDF — trois façons de décrire une loi.
5. Espérance et variance — versions théoriques de $\bar{x}$ et s^2.

Module 5 — Lois de probabilité usuelles

Objectifs du module 5

- Reconnaître les lois courantes et savoir laquelle s'applique à quel contexte business.
- Lire et interpréter une loi sans avoir à la calculer à la main.
- Maîtriser `scipy.stats` : `pdf`, `cdf`, `ppf`, `rvs`.

Plan du module

- Lois **discrètes** : Bernoulli, Binomiale, Poisson, Géométrique.
- Lois **continues** : Uniforme, Normale, Log-normale, Exponentielle.
- Lois des **tests** (mention) : Student, Chi^2, Fisher.
- Notion d'**odds** et **odds ratio**.

Vue d'ensemble des lois discrètes

Loi	**Modélise**	**Cas pharma**
Bernoulli(p)	Un essai binaire (succès / échec)	Patient répond-il au traitement ?
Binomiale(n, p)	Nombre de succès sur n essais	Patients qui répondent sur 100
Poisson(λ)	Comptage d'événements rares	Effets indésirables / jour
Géométrique(p)	Essais avant le 1er succès	Visites avant 1re prescription

Loi de Bernoulli

Loi de probabilité

$$\mathbb{P}(X = 1) = p, \qquad \mathbb{P}(X = 0) = 1 - p$$

$$\mathbb{E}[X] = p, \qquad \mathrm{Var}(X) = p(1 - p)$$

Lecture :

- La brique de base de toute la modélisation binaire.
- p est *le* paramètre — toute la loi est décrite par lui.
- Variance maximale en $p = 0{,}5$ (incertitude maximale), minimale en $p = 0$ ou 1 (certitude).

Cas pharma : clic sur une publicité, conversion d'un visiteur, succès d'un traitement, défaut sur un produit.

Loi binomiale $B(n, p)$

Loi de probabilité (discrète)

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, 1, \ldots, n\}$$

$$\mathbb{E}[X] = np, \qquad \mathrm{Var}(X) = np(1-p)$$

Lecture composant par composant :

- p^k : la proba que les k succès choisis arrivent.
- $(1-p)^{n-k}$: la proba que les $n-k$ autres soient des échecs.
- $\binom{n}{k} = \frac{n!}{k!(n-k)!}$: nombre de façons de choisir lesquels des n essais sont les succès.

Lien crucial : quand n devient grand, $B(n, p) \approx \mathcal{N}(np, np(1-p))$ (Moivre-Laplace). C'est un cas particulier du TCL (Module 6).

Loi de Poisson $\mathcal{P}(\lambda)$

Loi de probabilité

$$\mathbb{P}(X = k) = \frac{\lambda^k \, e^{-\lambda}}{k!}, \quad k \in \{0, 1, 2, \dots\}$$

$$\mathbb{E}[X] = \mathrm{Var}(X) = \lambda$$

Conditions d'application :

- Événements *rares*, *indépendants*, à *taux constant* sur l'intervalle observé.
- λ : nombre moyen d'événements par unité de temps ou d'espace.

Test rapide « est-ce une Poisson ? »

Si la moyenne empirique $\bar{x}$ et la variance empirique s^2 sont **très proches** dans vos données $\rightarrow$ Poisson plausible. Si $s^2 \gg \bar{x} \rightarrow$ surdispersion, autre loi (négative binomiale).

Loi géométrique (mention)

Loi de probabilité

Nombre d'essais avant le *premier* succès (p = proba de succès à chaque essai) :

$$\mathbb{P}(X = k) = (1-p)^{k-1}\, p, \quad k \in \{1, 2, 3, \dots\}$$

$$\mathbb{E}[X] = \frac{1}{p}, \qquad \mathrm{Var}(X) = \frac{1-p}{p^2}$$

Cas pharma typiques :

- Nombre de visites avant la première prescription d'un médicament.
- Nombre de tentatives avant qu'un patient supporte un traitement.
- Délai entre lancement d'une campagne et premier achat (en jours).

Loi sans mémoire : « ce qui s'est passé avant n'influence pas la suite ».

Vue d'ensemble des lois continues

Loi	**Modélise**	**Cas pharma**
Uniforme(a, b)	Tout est équiprobable sur $[a, b]$	Variable contrôlée, simulation
Normale $\mathcal{N}(\mu, \sigma^2)$	Somme de petits effets aléatoires	Scores cliniques agrégés
Log-normale	Produit de petits effets aléatoires	Dosage, durée d'effet, prix
Exponentielle(λ)	Durée entre événements rares	Temps entre 2 ventes rares
Student / Chi^2 / Fisher	Lois *des tests* (Module 8)	Lecture de p-values

Loi uniforme continue $U(a, b)$

Densité

$$f(x) = \frac{1}{b-a} \quad \text{pour } x \in [a, b], \quad 0 \text{ ailleurs}$$

$$\mathbb{E}[X] = \frac{a+b}{2}, \qquad \mathrm{Var}(X) = \frac{(b-a)^2}{12}$$

Lecture :

- Densité *constante* sur l'intervalle $\rightarrow$ chaque valeur a la même « chance » d'apparaître.
- Hors de $[a, b]$, la densité est nulle.
- Cas le plus simple, sert souvent de *baseline* (« et si tout était au hasard ? »).

Loi normale $\mathcal{N}(\mu, \sigma^2)$

Densité

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \qquad \mathbb{E}[X] = \mu, \ \ \mathrm{Var}(X) = \sigma^2$$

Pourquoi elle apparaît partout :

- Théorème central limite : la *somme* d'effets aléatoires indépendants tend vers une normale (cf. M6).
- Loi par *défaut* de presque tous les tests paramétriques.

Règle des 68-95-99,7

$$\mathbb{P}(|X-\mu| \le \sigma) \approx 68\,\%, \ \ \mathbb{P}(|X-\mu| \le 2\sigma) \approx 95\,\%, \ \ \mathbb{P}(|X-\mu| \le 3\sigma) \approx 99{,}7\,\%$$

Loi log-normale

Définition

X suit une log-normale si $\ln(X) \sim \mathcal{N}(\mu, \sigma^2)$.

$$f(x) = \frac{1}{x\,\sigma\sqrt{2\pi}}\,\exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0$$

$$\mathbb{E}[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right), \qquad \mathrm{Med}(X) = e^{\mu}$$

Pourquoi elle apparaît si souvent en business :

- Toujours *positive* (prix, durées, dosages, populations).
- Asymétrique à droite — quelques pics extrêmes.
- Le *produit* de petits effets aléatoires donne du log-normal (analogue multiplicatif du TCL).

Loi exponentielle $\mathrm{Exp}(\lambda)$

Densité

$$f(x) = \lambda\, e^{-\lambda x},\ \ x \geq 0 \qquad \mathbb{E}[X] = \frac{1}{\lambda},\ \ \mathrm{Var}(X) = \frac{1}{\lambda^2}$$

Lecture :

- Modélise une *durée d'attente* entre deux événements rares (équivalent continu de la géométrique).
- λ : taux par unité de temps ; $1/\lambda$: durée moyenne entre événements.
- Sans mémoire : si rien n'est arrivé pendant 10 min, la distribution restante reste la même.

Lien avec Poisson : si les événements suivent Poisson(λ), les *durées entre événements* suivent Exp(λ).

Lois des tests (mention)

Trois lois que vous croiserez en Module 8 — *pas* besoin de les calculer, juste de savoir d'où elles viennent.

Student t_ν

Apparaît dans le *t-test* (comparaison de moyennes). Forme : cloche similaire à la normale, mais queues plus lourdes pour ν petit. Quand $\nu \to \infty$, $t_\nu \to \mathcal{N}(0,1)$.

Chi^2 — χ^2_k

Apparaît dans le *test du chi-deux* (Module 3 & 8). Variable positive, asymétrique. $\mathbb{E}[\chi^2_k] = k$, $\mathrm{Var}(\chi^2_k) = 2k$.

Fisher $F(d_1, d_2)$

Apparaît dans l'*ANOVA* (Module 8). Rapport de deux χ^2 normalisés. Variable positive, asymétrique.

Odds et odds ratio

Définitions

$$\mathrm{Odds}(A) = \frac{\mathbb{P}(A)}{1 - \mathbb{P}(A)}, \qquad \mathrm{OR} = \frac{\mathrm{Odds}(A \mid \text{condition 1})}{\mathrm{Odds}(A \mid \text{condition 2})}$$

Lecture :

- Si $\mathbb{P}(A) = 0{,}25$: $\mathrm{Odds} = 0{,}25/0{,}75 = 1/3$ (« 1 contre 3 »).
- $\mathrm{OR} > 1$: la condition 1 *augmente* les chances de A ; $\mathrm{OR} = 1$: pas d'effet ; $\mathrm{OR} < 1$: *réduit* les chances.

Pourquoi vous en aurez besoin (Module 10)

La **régression logistique** produit des coefficients qui s'interprètent en odds ratios : $\mathrm{OR} = \exp(\beta)$ pour chaque variable explicative.

Manipuler les lois en Python : `scipy.stats`

Méthode	Calcule	Cas d'usage
`.pdf(x)`	densité en x	Tracer la courbe d'une loi continue
`.pmf(k)`	$\mathbb{P}(X = k)$	Loi discrète
`.cdf(x)`	$\mathbb{P}(X \leq x)$	Calcul de p-value, proba cumulée
`.sf(x)`	$\mathbb{P}(X > x) = 1 - \text{cdf}$	p-value côté droit
`.ppf(q)`	quantile d'ordre q	Trouver le seuil P95, P99
`.rvs(n)`	n tirages aléatoires	Simulation, bootstrap

Exemple — proba qu'une N02BE journalière dépasse 50 unités

`1 - stats.norm.cdf(50, loc=mu, scale=sigma)` ou `stats.norm.sf(50, mu, sigma)`

Cas pratique — ajustement empirique

Question : les ventes journalières d'une catégorie pharma suivent-elles une loi connue ?

Méthode en trois temps

1. **Hypothèse visuelle** : histogramme + KDE. Reconnaître la forme (cloche, asymétrique, entiers).
2. **Estimer les paramètres** de la loi candidate avec `scipy.stats.<loi>.fit(data)`.
3. **Vérifier l'ajustement** : QQ-plot (`probplot`) ; tests Kolmogorov-Smirnov ou Shapiro-Wilk.

Sur notre dataset pharma

R06 (antihistaminiques) : log-normale très probable.
Effets indésirables / jour : Poisson plausible si moyenne $\approx$ variance.

Pièges courants — Module 5

Ne pas tomber dedans

1. **Forcer la normalité partout** — beaucoup de phénomènes business sont log-normaux ou Poissoniens.
2. Confondre la **loi théorique** (modèle) et la **distribution empirique** (données).
3. Appliquer Poisson sur des données *surdispersées* ($s^2 \gg \bar{x}$).
4. Lire la densité $f(x)$ comme une probabilité.
5. Confondre **odds** et **probabilité** dans une présentation business — l'audience entend toujours « probabilité ».

À retenir — Module 5

Quatre réflexes pour choisir une loi

1. **Discret ou continu** ? On élimine déjà la moitié des candidates.
2. **Symétrique ou asymétrique** ? Cloche $\rightarrow$ normale ; queue à droite $\rightarrow$ log-normale, exponentielle.
3. **Borné ou non** ? Borné à 0 $\rightarrow$ Poisson, exponentielle, log-normale.
4. **Moyenne $\approx$ variance** ? Indice fort de Poisson.

Et toujours : confirmer visuellement avec un QQ-plot avant de modéliser.

Synthèse de la partie 2

Ce que vous savez faire à la fin de la partie 2

- Manipuler le vocabulaire probabiliste : événement, variable aléatoire, loi, espérance, variance.
- Calculer une probabilité conditionnelle et appliquer Bayes.
- Distinguer PMF, PDF, CDF — savoir laquelle utiliser pour quel calcul.
- Reconnaître les lois usuelles (Bernoulli, binomiale, Poisson, normale, log-normale, exponentielle).
- Lire et interpréter une odds ratio.
- Manipuler une loi avec `scipy.stats` : `pdf`, `cdf`, `ppf`, `rvs`.

Suite de la formation

Partie 3 — Statistiques inférentielles (M6-M10)

Du descriptif et du probabiliste à la décision : intervalles de confiance, tests d'hypothèses, régression linéaire et logistique.

Liens explicites avec la partie 2 que nous activerons

- Module 6 : le **TCL** s'appuie sur les lois et l'espérance vues ici.
- Module 7 : la **p-value** est une probabilité conditionnelle (M4).
- Module 8 : chaque test repose sur une loi de référence (Student, χ^2, Fisher).
- Module 10 : la régression logistique s'interprète en **odds ratios** (M5).

Questions ?

Pause avant la partie inférentielle

Bassem Ben Hamed — bassem.benhamed@enetcom.usf.tn