De la donnée à la décision

Statistiques pour les Experts Data

Partie 3 — Statistiques inférentielles

Modules 6 à 10

Bassem Ben Hamed

bassem.benhamed@enetcom.usf.tn

Formation interne

Plan de la partie 3

Module 6 — De l'échantillon à la population

Module 7 — Tests d'hypothèses : la logique

Module 8 — Choisir le bon test

Module 9 — Régression linéaire

Module 10 — Régression logistique

Où en sommes-nous ?

Architecture de la formation (5 parties, 17 modules)

Partie	Modules
1. Descriptive	M0 Introduction, M1 Décrire, M2 Visualiser, M3 Relations
2. Probabilités	M4 Vocabulaire probabiliste, M5 Lois usuelles
3. Inférentielle	**M6 Échantillon → population, M7 Tests d'hypothèses, M8 Choisir le bon test, M9 Régression linéaire, M10 Régression logistique**
4. Séries temporelles	M11 Spécificités, M12 Préparation, M13 Stationnarité, M14 SARIMA & Prophet, M15 Anomalies
5. Synthèse	M16 Communication, M17 Récapitulatif

Le cœur de la pratique du data analyst

Cette partie 3 est la plus longue et la plus utilisée au quotidien : A/B tests, KPIs avec marge d'erreur, ANOVA entre groupes, modèles explicatifs.

Pourquoi l'inférence ?

Le problème

- On observe un *échantillon* (ce qu'on a).
- On veut conclure sur la *population* (ce qu'on n'a pas).
- Comment quantifier la certitude de cette généralisation ?

Les outils

- **Intervalles de confiance** (M6) — donner une marge d'erreur.
- **Tests d'hypothèses** (M7-M8) — décider si un effet est réel.
- **Régression** (M9-M10) — modéliser une relation.

Fondations

Toute la partie 3 s'appuie sur les notions de probabilité de la Partie 2 : variable aléatoire, lois usuelles, espérance.

Module 6 — De l'échantillon à la population

Objectifs du module 6

- Comprendre pourquoi on a besoin d'inférence.
- Saisir le théorème central limite (TCL) intuitivement.
- Construire et lire un intervalle de confiance.
- Calculer la taille d'échantillon nécessaire pour une précision donnée.

Population vs échantillon — rappel

Le problème de l'analyst

- On veut connaître μ (paramètre de la population), *inconnue*.
- On observe $\bar{x}$ (estimation sur un échantillon de taille n).
- Question : à quel point $\bar{x}$ est-il une « bonne » estimation de μ ?

Cas pharma

Notre dataset : 6 ans de ventes d'**une** pharmacie. La « population » serait l'ensemble des ventes possibles dans des conditions similaires. On ne la connaîtra jamais.

Méthodes d'échantillonnage

Trois méthodes courantes

Aléatoire simple Chaque individu a la même probabilité d'être tiré.

Stratifié On divise la population en strates homogènes (ex : par âge), on tire dans chaque strate.

Systématique On prend 1 individu sur k dans une liste ordonnée.

Biais d'échantillonnage à éviter

- **Biais de sélection** : « les répondants à un sondage » $\neq$ population générale.
- **Biais de survie** : on ne voit que ce qui a survécu.
- **Biais de couverture** : la liste de sondage exclut une partie de la population.

Distribution d'échantillonnage

Notion clé

Si on répétait l'expérience un grand nombre de fois (chaque fois un nouvel échantillon de taille n), on obtiendrait une distribution de *moyennes échantillonnales* $\bar{x}_1, \bar{x}_2, \ldots$ Cette distribution s'appelle la **distribution d'échantillonnage de la moyenne**.

Trois propriétés à comprendre :

- Centre : $\mathbb{E}[\bar{X}] = \mu$ (estimateur *sans biais*).
- Dispersion : $\mathrm{Var}(\bar{X}) = \sigma^2/n$ — diminue avec n.
- Forme : tend vers une *normale* quand n grandit (TCL).

C'est cette distribution qui rend l'inférence possible.

Théorème central limite (TCL)

Énoncé intuitif

Soit $X_1, \ldots, X_n$ des v.a. *indépendantes*, de même loi, d'espérance μ et variance σ^2. Alors, pour n assez grand :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Lecture :

- Peu importe la loi d'origine (Poisson, log-normale, exponentielle...).
- Plus n grandit, plus la moyenne échantillonnale est proche d'une normale.
- **Pierre angulaire** de l'inférence : la normale s'applique presque partout.

Règle pratique : $n \geq 30$ suffit dans la plupart des cas (sauf distributions très asymétriques).

TCL — démonstration visuelle

Expérience

On tire des échantillons de taille n depuis une loi *log-normale* (très asymétrique). On calcule $\bar{x}$ pour chaque échantillon. On répète 10 000 fois et on trace la distribution des $\bar{x}$.

Observation :

- $n = 1$: la distribution des « moyennes » est log-normale (asymétrique).
- $n = 5$: déjà moins asymétrique.
- $n = 30$: forme de cloche, presque gaussienne.
- $n = 100$: indistinguable d'une gaussienne.

Démo en notebook (`03_stats_inferentielles.ipynb`).

Erreur standard vs écart-type

Deux notions à ne jamais confondre

- **Écart-type** (σ ou s) : dispersion des *observations* dans la population (ou l'échantillon).
- **Erreur standard** (SE) : dispersion de la *moyenne échantillonnale*.

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}$$

Conséquence : l'erreur standard *décroît en* $1/\sqrt{n}$.

- Diviser SE par 2 $\Rightarrow$ il faut $\times 4$ d'observations.
- Diviser SE par 10 $\Rightarrow$ il faut $\times 100$ d'observations.

C'est pourquoi le ROI marginal d'un sondage chute rapidement avec la taille.

Intervalle de confiance — construction

Formule (cas σ connu, ou n grand)

$$\mathrm{IC}_{1-\alpha} = \left[\bar{x} - z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}} \ , \ \bar{x} + z_{1-\alpha/2} \cdot \frac{s}{\sqrt{n}} \right]$$

Lecture composant par composant :

- $\bar{x}$: centre — meilleure estimation ponctuelle.
- $s/\sqrt{n}$: erreur standard — incertitude sur la moyenne.
- $z_{1-\alpha/2}$: quantile de la normale (par ex. $z_{0{,}975} = 1{,}96$ pour 95 %).

Cas σ inconnu et n petit

On remplace z par $t_{n-1,1-\alpha/2}$ (quantile de **Student**, M5). Pour n grand, $t \to z$.

IC à 95 % — exemple chiffré

Cas pharma : moyenne mensuelle des ventes N02BE

Sur un échantillon de $n = 60$ mois :

- $\bar{x} = 904{,}3$ unités/mois
- $s = 215{,}7$
- $SE = 215{,}7/\sqrt{60} \approx 27{,}9$
- $z_{0{,}975} = 1{,}96$

$$\mathrm{IC}_{95\%} = [904{,}3 - 1{,}96 \times 27{,}9\ ;\ 904{,}3 + 1{,}96 \times 27{,}9] \approx [849{,}6\ ;\ 959{,}0]$$

Lecture business : « Avec une confiance de 95 %, la vraie moyenne mensuelle se situe entre 850 et 959 unités. »

IC — lecture correcte vs erreur classique

La phrase qu'on entend tout le temps (et qui est fausse)

« Il y a 95 % de chances que la vraie moyenne μ soit dans [849,6 ; 959,0]. »

La lecture fréquentiste correcte

« Si on répétait cette expérience un grand nombre de fois, 95 % des intervalles construits contiendraient la vraie valeur μ. »

Pourquoi la nuance compte :

- μ est *fixe* (mais inconnue) — pas de probabilité associée à elle.
- C'est l'*intervalle* qui est aléatoire (il dépend de l'échantillon).
- En pratique, vous lirez le résultat comme une « marge d'erreur » — c'est acceptable, mais sachez ce que c'est vraiment.

Taille d'échantillon nécessaire

Formule (estimation d'une moyenne, marge E)

Pour un IC à $1-\alpha$ de *demi-largeur* E : $n \geq \left(\dfrac{z_{1-\alpha/2}\cdot\sigma}{E}\right)^2$

Pour estimer une proportion p :

$$n \geq \frac{z_{1-\alpha/2}^2 \cdot p(1-p)}{E^2} \quad \text{(majoration : prendre } p = 0{,}5\text{)}$$

Calcul-type

Estimer un taux de conversion à ± 2 points près (95 %, $p \approx 0{,}5$) : $n \geq \dfrac{1{,}96^2 \times 0{,}25}{0{,}02^2} \approx 2\,401.$

À retenir — Module 6

Quatre réflexes inférentiels

1. Toujours distinguer **écart-type** (s) et **erreur standard** ($s/\sqrt{n}$).
2. Le **TCL** permet d'utiliser la normale même quand la loi d'origine ne l'est pas — à condition que n soit assez grand.
3. Un IC est une affirmation sur le *procédé*, pas sur la *vraie valeur*.
4. Pour réduire la marge d'erreur *de moitié*, il faut *multiplier* la taille de l'échantillon par 4.

Module 7 — Tests d'hypothèses : la logique

Objectifs du module 7

- Maîtriser la logique d'un test, sans se perdre dans les formules.
- Interpréter correctement une p-value.
- Comprendre les notions de puissance et de taille d'effet.
- Reconnaître le p-hacking et le piège des comparaisons multiples.

Hypothèses H_0 vs H_1

Logique du test (raisonnement par l'absurde)

- H_0 — **hypothèse nulle** : « il ne se passe rien » (pas d'effet, statu quo).
- H_1 — **hypothèse alternative** : « il y a un effet » (ce qu'on cherche).

Procédure : on suppose H_0 vraie, on observe les données. Si elles sont *très improbables* sous $H_0 \Rightarrow$ rejet ; sinon, on *ne rejette pas* (ce n'est pas la même chose qu'« accepter »).

Cas pharma — A/B test

H_0 : « le nouveau packaging ne change rien aux ventes. »
H_1 : « le nouveau packaging modifie les ventes. »

p-value — définition formelle

Définition

$$p\text{-value} = \mathbb{P}(\text{observer des données au moins aussi extrêmes} \mid H_0 \text{ vraie})$$

Lecture composant par composant :

- C'est une probabilité conditionnelle (cf. Module 4).
- « Au moins aussi extrêmes » : selon le test bilatéral / unilatéral.
- *Si* H_0 est vraie : on suppose que rien ne se passe.
- Petite p-value $\Rightarrow$ les données sont peu compatibles avec H_0 $\Rightarrow$ on rejette.

Convention

Seuil $\alpha = 0{,}05$ par habitude. Si $p < \alpha$: « significatif ». Sinon : « non significatif ».

p-value — ce qu'elle ne dit PAS

Cinq erreurs classiques

1. « p est la probabilité que H_0 soit vraie. » *Faux* — H_0 est vraie ou fausse, pas probabilisée (cadre fréquentiste).
2. « $p < 0{,}05$ donc l'effet est important. » *Faux* — significativité $\neq$ taille d'effet.
3. « $p = 0{,}06$ donc il n'y a pas d'effet. » *Faux* — c'est juste qu'on n'a pas assez de preuves.
4. « p est la probabilité que les données viennent du hasard. » *Mal formulé*.
5. « Une p-value plus petite = effet plus grand. » *Faux* — une grande taille d'échantillon donne aussi des p très petites.

Erreurs de type I et type II

	H_0 **vraie**	H_0 **fausse**
On rejette H_0	Type I (α)	Décision correcte
On ne rejette pas H_0	Décision correcte	Type II (β)

Lecture :

- **Type I** (α) : faux positif — on conclut à un effet alors qu'il n'y en a pas.
- **Type II** (β) : faux négatif — on rate un effet réel.
- Réduire $\alpha \Rightarrow$ augmente β (et inversement). Pas de repas gratuit.

Cas pharma

Type I : on déploie un médicament inefficace. Type II : on jette un médicament efficace.

Puissance statistique

Définition

$$\text{Puissance} = 1 - \beta = \mathbb{P}(\text{rejeter } H_0 \mid H_1 \text{ vraie})$$

« Probabilité de *détecter* un effet quand il existe vraiment. » **Quatre leviers pour augmenter la puissance :**

1. Augmenter n (le levier principal).
2. Augmenter la taille de l'effet recherché (chercher des effets gros).
3. Réduire la variabilité σ (mesures plus précises).
4. Augmenter α (mais on accepte plus de faux positifs).

Convention

On vise généralement **puissance** $\geq 0{,}80$ pour un test bien dimensionné.

Taille d'effet

Une p-value seule ne dit *rien* sur l'ampleur de l'effet. La taille d'effet la complète.

Cohen's d (différence de moyennes)

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{\text{pooled}}} \quad \text{avec } s_{\text{pooled}} = \text{écart-type combiné}$$

Repères : $|d| < 0{,}2$ négligeable ; $\approx 0{,}2$ faible ; $\approx 0{,}5$ moyen ; $\geq 0{,}8$ fort. **Toujours reporter taille d'effet *et* p-value.** Si l'audience est business : reporter d ou la *différence en %*, pas seulement « significatif ».

Tests unilatéraux vs bilatéraux

La règle absolue

Choisir l'orientation du test avant de regarder les données. Sinon, c'est du p-hacking.

- **Bilatéral** ($H_1 : \mu \neq \mu_0$) : on rejette si l'écart est extrême *dans un sens ou dans l'autre*. Cas par défaut.
- **Unilatéral** ($H_1 : \mu > \mu_0$ ou $\mu < \mu_0$) : seul un sens compte. La p-value est alors la *moitié* de celle du bilatéral.

Cas pharma

« Le nouveau traitement est-il *meilleur* (et pas juste différent) ? » $\rightarrow$ test unilatéral.
« Y a-t-il une *différence* (peu importe le sens) ? » $\rightarrow$ test bilatéral.

p-hacking et comparaisons multiples

Le piège

Si on teste k hypothèses au seuil $\alpha = 0{,}05$, en moyenne $0{,}05 \cdot k$ seront « significatives » *par pur hasard*.

Deux corrections classiques

Bonferroni $\alpha' = \alpha / k$. Très conservatif, mais simple.

Benjamini-Hochberg Contrôle le *taux de fausses découvertes* (FDR). Moins conservatif que Bonferroni.

Cas typique

Une matrice de corrélation entre 20 variables $= \binom{20}{2} = 190$ tests. Au seuil 5 %, on attend $\sim 9{,}5$ corrélations « significatives » par hasard. Sans correction, on raconte n'importe quoi.

À retenir — Module 7

Le mantra du test

1. Formuler H_0 et H_1 avant de voir les données.
2. Choisir le seuil α et la puissance avant aussi.
3. Toujours reporter la **taille d'effet**, pas seulement la p-value.
4. « Non significatif » $\neq$ « pas d'effet ».
5. Si on fait beaucoup de tests, **corriger** (Bonferroni / BH).

Module 8 — Choisir le bon test

Objectifs du module 8

- Disposer d'un arbre de décision pratique pour les tests les plus courants.
- Comprendre le lien entre chaque test et sa *loi de référence* (Student, χ^2, Fisher — vues en M5).
- Savoir quand préférer un test *non paramétrique*.

Arbre de décision — vue d'ensemble

Question	**Test recommandé**	**Conditions**
Comparer une moyenne à une référence	t-test 1 échantillon	Normalité ou n grand
Comparer 2 groupes indépendants	t-test indép. / Welch	Normalité, variances
Comparer 2 groupes (non normal)	Mann-Whitney U	—
Avant / après (mêmes individus)	t-test apparié / Wilcoxon	—
Comparer ≥ 3 groupes	ANOVA / Kruskal-Wallis	—
Indépendance de 2 var. qualitatives	χ^2 / Fisher exact	Effectifs attendus
Comparer 2 proportions	Test z de proportion	n grand
Tester la normalité	Shapiro-Wilk, QQ-plot	$n < 5000$

t-test à 1 échantillon

Statistique de test

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1} \quad \text{sous } H_0$$

Question : la moyenne d'un échantillon diffère-t-elle d'une valeur de référence μ_0 ?

- Numérateur : écart entre la moyenne observée et la référence.
- Dénominateur : erreur standard (M6).
- La statistique t suit une loi de **Student** à $n-1$ degrés de liberté.
- p-value = quantile sur t_{n-1} (méthode `stats.ttest_1samp`).

Cas pharma : « Les ventes mensuelles dépassent-elles le seuil contractuel de 800 unités ? »

t-test à 2 échantillons indépendants — Welch

Statistique de Welch

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Pourquoi Welch plutôt que Student classique :

- Pas besoin de supposer l'égalité des variances entre les deux groupes (hypothèse souvent fausse en pratique).
- En `scipy` : `stats.ttest_ind(x1, x2, equal_var=False)`.

Cas pharma

Comparer la moyenne des ventes *week-end* vs *semaine* pour N02BE.

Mann-Whitney U — alternative non paramétrique

Quand l'utiliser : distribution *non* normale, petits échantillons, présence d'outliers, ou variable ordinale. **Principe :**

- On combine les deux groupes, on classe par rangs.
- On compare les sommes de rangs entre groupes.
- Teste si une distribution est *stochastiquement plus grande* que l'autre.

```
scipy.stats.mannwhitneyu(x1, x2, alternative='two-sided')
```

À retenir

En cas de doute sur la normalité $\rightarrow$ Mann-Whitney plutôt que t-test mal calibré.

Tests appariés — avant / après

t-test apparié

On calcule les différences $d_i = x_i^{\text{après}} - x_i^{\text{avant}}$, puis on teste si $\mathbb{E}[D] = 0$.

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} \sim t_{n-1}$$

Pourquoi c'est plus puissant qu'un test à 2 échantillons indépendants : on *contrôle* la variabilité inter-individus. **Variante non paramétrique :** test des rangs signés de **Wilcoxon**.

Cas pharma

« Le temps de réponse moyen d'un traitement est-il plus court qu'avant la nouvelle posologie ? » $\rightarrow$ chaque patient est sa propre référence.

ANOVA — comparer 3 groupes ou plus

Statistique de Fisher

$$F = \frac{MS_{\text{inter}}}{MS_{\text{intra}}} = \frac{SS_{\text{inter}}/(g-1)}{SS_{\text{intra}}/(n-g)} \sim F(g-1, n-g) \quad \text{sous } H_0$$

Lecture :

- g = nombre de groupes, n = total.
- Numérateur : variance *entre* groupes.
- Dénominateur : variance *intra*-groupe.
- Si le rapport est grand $\rightarrow$ les groupes sont *vraiment* différents.

Cas non paramétrique : Kruskal-Wallis

Même esprit, mais sur les rangs.

Cas pharma : « Les ventes diffèrent-elles entre les 8 catégories ATC ? »

χ^2 et test exact de Fisher

Statistique du chi-deux (rappel M3)

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(r-1)(c-1)}$$

Quand utiliser :

- Test d'*indépendance* entre 2 variables qualitatives.
- Conditions : effectifs attendus $E_{ij} \geq 5$ dans toutes les cases.

Test exact de Fisher

Quand les effectifs sont petits ($E_{ij} < 5$) ou tableaux 2×2. Calcul exact, pas d'approximation.

`scipy.stats.chi2_contingency` et `scipy.stats.fisher_exact`.

Comparer deux proportions

Test z de proportion

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

avec $\hat{p}$ = proportion combinée des deux groupes.

Cas d'usage type : A/B test sur un taux de conversion, taux de réponse à un traitement.

Cas pharma

Variant A : 230 conversions / 5 000 visiteurs ($\hat{p}_1 = 4{,}6\,\%$).

Variant B : 280 conversions / 5 000 visiteurs ($\hat{p}_2 = 5{,}6\,\%$).

Le z-test dit si la différence d'1 point est significative.

Tests de normalité

Avant d'utiliser un test paramétrique, on vérifie la normalité.

Trois outils

QQ-plot Visuel — points alignés sur la diagonale = normal.

Shapiro-Wilk Statistique formelle, valable pour $n < 5\,000$.

Kolmogorov-Smirnov Comparaison de CDF empirique vs théorique.

Attention

Sur un grand échantillon, les tests rejettent la normalité *même* pour des écarts insignifiants. Préférer le **QQ-plot** et le bon sens.

Cas pratique — A/B test sur un taux de conversion

Pipeline complet

1. **Question** : le variant B convertit-il mieux que A ?
2. **Hypothèses** : $H_0 : p_A = p_B$; $H_1 : p_A \neq p_B$ (bilatéral).
3. **Seuil** : $\alpha = 0{,}05$, puissance visée 80 %.
4. **Taille minimale** : calculée *avant* l'expérience.
5. **Test** : z de proportion (`statsmodels.stats.proportions_ztest`).
6. **Résultats** : reporter p_A, p_B, différence, IC sur la différence, p-value, taille d'effet.
7. **Conclusion** : décision business + limite de l'analyse.

À retenir — Module 8

Quatre questions avant de choisir un test

1. Quelle est la **nature** de la variable cible (quantitative, qualitative, proportion) ?
2. Combien de **groupes** compare-t-on ?
3. Les groupes sont-ils **indépendants** ou **appariés** ?
4. Les conditions du test paramétrique (normalité, variances) sont-elles vérifiées ? Sinon $\rightarrow$ non paramétrique.

Module 9 — Régression linéaire

Objectifs du module 9

- Comprendre la régression comme outil d'explication et d'estimation d'effet.
- Lire les coefficients « toutes choses égales par ailleurs ».
- Vérifier les hypothèses du modèle.
- Interpréter un `summary` de `statsmodels`.

Régression linéaire simple

Modèle

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Lecture :

- β_0 : ordonnée à l'origine — valeur de y quand $x = 0$.
- β_1 : pente — variation de y pour une augmentation de *1 unité* de x.
- ε_i : bruit (résidu), supposé gaussien centré.

Méthode des moindres carrés (OLS)

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{\beta_0, \beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

Solution OLS et lien avec la corrélation

Formules fermées

$$\hat{\beta}_1 = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)} = r \cdot \frac{s_Y}{s_X}, \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Lien important :

- La pente $\hat{\beta}_1$ est proportionnelle au coefficient de Pearson r (Module 3).
- La droite passe *toujours* par $(\bar{x}, \bar{y})$.

Coefficient de détermination R^2

Formule

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

Lecture :

- Proportion de variance de y *expliquée par le modèle*.
- $R^2 \in [0, 1]$: 0 = modèle inutile, 1 = ajustement parfait.
- En régression *simple* : $R^2 = r^2$.

R^2 élevé n'est PAS un gage de bon modèle

- Surapprentissage possible (trop de variables).
- Préférer le R^2 *ajusté* en multivariée.
- Toujours regarder les *résidus* en plus du R^2.

Régression linéaire multiple

Modèle

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

Forme matricielle : $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ avec $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$.

Lecture cruciale :

- β_j : effet de x_j sur y, toutes les autres variables tenues constantes.
- C'est différent de la simple corrélation entre x_j et y.
- C'est ce qui permet de *contrôler* pour des variables confondantes (cf. Simpson, M3).

Cas pharma

```
ventes_N02BE ~ jour_semaine + mois + saison + année
```

Variables catégorielles — encodage one-hot

Principe

Une variable qualitative à k modalités $\Rightarrow$ $k-1$ variables binaires (la k-ième est la *modalité de référence*).

Exemple — saison (4 modalités) :

- Référence : `automne`.
- Coefficients du modèle : `saison_hiver`, `saison_printemps`, `saison_été`.
- Lecture : « être en été augmente y de $\hat{\beta}_{\text{été}}$ par rapport à l'automne. »

Piège

Le *choix de la modalité de référence* change la lecture des coefficients (mais pas le modèle global). Toujours préciser laquelle.

Hypothèses du modèle linéaire

Quatre hypothèses à vérifier

Linéarité $\mathbb{E}[y \mid X] = X\beta$ — la relation est linéaire dans les paramètres.

Indépendance Les ε_i sont indépendants — souvent faux sur les séries temporelles !

Homoscédasticité $\mathrm{Var}(\varepsilon_i) = \sigma^2$ constante.

Normalité des résidus $\varepsilon_i \sim \mathcal{N}$ — pour les p-values et IC.

À quoi servent-elles concrètement ?

- Linéarité & indépendance $\rightarrow$ *validité* de l'estimation $\hat{\beta}$.
- Homoscédasticité & normalité $\rightarrow$ *validité* des p-values et IC.

Diagnostiquer avec un graphique des résidus + un QQ-plot.

Lire un `summary` de `statsmodels`

Sortie	Lecture
`coef`	Estimation $\hat{\beta}_j$
`std err`	Erreur standard de $\hat{\beta}_j$
`t`	Statistique $t = \hat{\beta}_j / \mathrm{SE}$
`P>|t|`	p-value bilatérale ($H_0 : \beta_j = 0$)
`[0.025, 0.975]`	IC à 95 % sur β_j
`R-squared`	R^2
`Adj. R-squared`	R^2 ajusté (pénalise les variables inutiles)
`F-statistic`	Test global du modèle ($H_0 : \beta_1 = \cdots = \beta_p = 0$)

Lecture pratique : d'abord la `F-statistic` (modèle globalement utile ?), puis chaque `P>|t|` (variables individuellement significatives ?), enfin les *IC* pour l'amplitude de l'effet.

Multicolinéarité et VIF

Problème

Quand deux variables explicatives sont fortement corrélées, leurs coefficients deviennent *instables* (grands écarts-types, signes imprévisibles).

Variance Inflation Factor

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

où R_j^2 est le R^2 de la régression de x_j sur les autres variables explicatives.

Repères :

- $\mathrm{VIF} < 5$: OK.
- $5 \leq \mathrm{VIF} < 10$: à surveiller.
- $\mathrm{VIF} \geq 10$: multicolinéarité sévère $\rightarrow$ retirer ou combiner des variables.

Pièges courants — Module 9

Ne pas tomber dedans

1. **Extrapoler hors du domaine** des données d'entraînement.
2. Interpréter β_j causalement sans précaution (« X cause Y »).
3. Croire qu'un R^2 **élevé** = bon modèle. Toujours vérifier les résidus.
4. Oublier la **multicolinéarité** : des coefficients absurdes peuvent en découler.
5. Faire une régression linéaire sur une cible **binaire** (cf. Module 10).

À retenir — Module 9

Cinq questions à se poser après chaque régression

1. Le modèle est-il globalement utile (F-stat, R^2 ajusté) ?
2. Quelles variables sont individuellement significatives ?
3. Les hypothèses sont-elles vérifiées (résidus, QQ-plot) ?
4. Y a-t-il de la multicolinéarité (VIF) ?
5. Les coefficients ont-ils un sens *métier* ?

Module 10 — Régression logistique

Objectifs du module 10

- Modéliser une variable cible binaire.
- Interpréter les coefficients en odds ratios (Module 5).
- Évaluer un classifieur binaire : matrice de confusion, précision, rappel, AUC.
- Choisir un seuil de décision adapté au coût des erreurs.

Pourquoi pas une régression linéaire sur 0/1 ?

Trois problèmes

1. Les prédictions $\hat{y}$ peuvent sortir de $[0, 1]$ — interprétation absurde comme probabilité.
2. Les résidus ne peuvent pas être gaussiens.
3. L'hypothèse d'homoscédasticité est forcément violée (la variance dépend de p).

Solution : transformer la cible avec la fonction logit, qui mappe $[0, 1] \to (-\infty, +\infty)$.

Le modèle logistique

Formulation

$$\text{logit}(\mathbb{P}(Y = 1 \mid X)) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

Ou de manière équivalente :

$$p = \mathbb{P}(Y = 1 \mid X) = \frac{1}{1 + \exp(-(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p))}$$

Lecture :

- Le *log des odds* est linéaire en X.
- La fonction *sigmoïde* ramène à une probabilité dans $[0, 1]$.
- Estimation par maximum de vraisemblance (pas par moindres carrés).

Lecture des coefficients en odds ratio

Règle clé

$$\mathrm{OR} = \exp(\beta_j)$$

Une augmentation d'*une unité* de x_j multiplie les odds de $Y = 1$ par $\exp(\beta_j)$.

Exemples chiffrés :

- $\beta_j = 0 \Rightarrow \mathrm{OR} = 1$: pas d'effet.
- $\beta_j = 0{,}69 \Rightarrow \mathrm{OR} = 2$: double les odds.
- $\beta_j = -1{,}10 \Rightarrow \mathrm{OR} = 0{,}33$: divise les odds par 3.

Cas pharma

Modèle : `forte_vente_N02BE ~ weekend + saison_hiver`.

Si $\beta_{\text{weekend}} = -1{,}5$: $\mathrm{OR} = e^{-1{,}5} \approx 0{,}22$.

« Être en week-end *divise* par $\sim 4{,}5$ les odds d'une forte vente N02BE. »

Évaluation — matrice de confusion

	Prédit 1	**Prédit 0**
Réel 1 (positif)	TP (vrai positif)	FN (faux négatif)
Réel 0 (négatif)	FP (faux positif)	TN (vrai négatif)

Métriques dérivées :

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}, \quad \text{Précision} = \frac{TP}{TP+FP}, \quad \text{Rappel} = \frac{TP}{TP+FN}$$

$$F_1 = \frac{2 \cdot \text{Précision} \cdot \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

Précision : « quand je dis positif, ai-je raison ? » *Rappel* : « est-ce que je rate des vrais positifs ? »

Quelle métrique selon le contexte ?

Contexte	Coût d'un FP	Coût d'un FN
Filtrage anti-spam	spam visible (faible)	e-mail légitime perdu (élevé)
Détection de fraude	client gêné (faible)	fraude non détectée (élevé)
Diagnostic médical (cancer)	test de confirm. (modéré)	cancer raté (très élevé)
Recommandation produit	utilisateur ennuyé (faible)	vente ratée (modéré)

Règle :

- Coût FN dominant $\rightarrow$ optimiser le **rappel**.
- Coût FP dominant $\rightarrow$ optimiser la **précision**.
- Coûts & classes équilibrés $\rightarrow$ **accuracy** ou F_1.

Courbe ROC et AUC

Construction

En faisant varier le seuil de décision de 0 à 1, on trace :

- Axe y : *rappel* (TPR) $= TP/(TP + FN)$.
- Axe x : taux de faux positifs (FPR) $= FP/(FP + TN)$.

AUC (Area Under the Curve) :

- AUC $= 0{,}5$: modèle aléatoire.
- AUC $= 1$: modèle parfait.
- AUC $\geq 0{,}8$: généralement considéré comme bon.

Limite avec classes déséquilibrées

Avec une classe minoritaire à 1 %, l'AUC peut être trompeuse. Préférer la **courbe Précision-Rappel** dans ce cas.

Seuil de décision

Le piège du seuil par défaut

`predict()` utilise par défaut le seuil 0,5 : $\hat{y} = 1$ si $\hat{p} \geq 0{,}5$.

Pourquoi ce n'est pas toujours le bon choix :

- Avec des classes déséquilibrées (1 % de positifs), 0,5 produit presque toujours $\hat{y} = 0$.
- Le seuil optimal dépend du *ratio des coûts* d'erreur.

Approche recommandée :

1. Tracer la courbe précision-rappel.
2. Choisir le seuil qui optimise le critère métier (rappel à 80 %, précision minimale fixée, etc.).
3. Documenter ce choix.

Pièges courants — Module 10

Ne pas tomber dedans

1. Interpréter les coefficients comme une régression linéaire (échelle logit $\neq$ échelle directe).
2. Confondre **odds** et **probabilité** dans une présentation business.
3. Reporter une « accuracy de 99 % » sur un dataset à 1 % de positifs (modèle inutile mais accuracy élevée).
4. Utiliser le seuil 0,5 sans réfléchir au coût des erreurs.
5. Ignorer les hypothèses de la régression logistique (linéarité du *logit*, indépendance).

À retenir — Module 10

Pipeline d'une régression logistique

1. **Préparer** les variables (one-hot, standardisation si besoin).
2. **Ajuster** avec `statsmodels` (`Logit`) ou `sklearn` (`LogisticRegression`).
3. **Lire** les coefficients en odds ratios.
4. **Évaluer** : matrice de confusion + précision/rappel adaptés au métier.
5. **Calibrer** le seuil de décision selon le coût des erreurs.
6. **Communiquer** en probabilités, pas en odds.

Synthèse de la partie 3

Ce que vous savez faire à la fin de la partie 3

- Construire et interpréter un **intervalle de confiance**.
- Formuler H_0/H_1 et lire correctement une **p-value**.
- Choisir le **test** adapté à votre question (arbre de décision M8).
- Ajuster une **régression linéaire** multiple, vérifier ses hypothèses, lire son `summary`.
- Ajuster une **régression logistique**, l'interpréter en odds ratios, choisir un seuil de décision.
- Éviter les pièges classiques : p-hacking, multicolinéarité, accuracy trompeuse.

Suite de la formation

Partie 4 — Séries temporelles (M11-M15)

Cas particulier où le *temps compte* : décomposition, stationnarité, SARIMA, Prophet, détection d'anomalies.

Liens explicites avec la partie 3

- Module 14 : les **intervalles de prédiction** sont l'analogue temporel des IC vus ici.
- Module 14 : la **validation temporelle** (rolling origin) remplace la validation croisée classique.
- Module 15 : la **détection d'anomalies** s'appuie sur des seuils dérivés de lois (M5).

Questions ?

Pause avant la partie séries temporelles

Bassem Ben Hamed — bassem.benhamed@enetcom.usf.tn