De la donnée à la décision

Statistiques pour les Experts Data

Partie 4 — Séries temporelles

Modules 11 à 15

Bassem Ben Hamed

bassem.benhamed@enetcom.usf.tn

Formation interne

Plan de la partie 4

Module 11 — Spécificités des séries temporelles

Module 12 — Exploration et préparation

Module 13 — Stationnarité & autocorrélation

Module 14 — Modèles de prévision

Module 15 — Détection d'anomalies

Où en sommes-nous ?

Architecture de la formation (5 parties, 17 modules)

Partie	Modules
1. Descriptive	M0 Introduction, M1 Décrire, M2 Visualiser, M3 Relations
2. Probabilités	M4 Vocabulaire probabiliste, M5 Lois usuelles
3. Inférentielle	M6 Échantillon → population, M7 Tests, M8 Choisir le bon test, M9 Régression linéaire, M10 Régression logistique
4. Séries temporelles	**M11 Spécificités, M12 Préparation, M13 Stationnarité & ACF, M14 SARIMA & Prophet, M15 Anomalies**
5. Synthèse	M16 Communication, M17 Récapitulatif

Le cas particulier où le temps compte

Une série temporelle, c'est des données ordonnées dans le temps. Cette partie introduit les outils spécifiques pour les analyser et les prévoir.

Pourquoi les séries temporelles sont différentes

Ce qui change

- Les observations *dépendent* les unes des autres (autocorrélation).
- L'ordre est essentiel.
- L'hypothèse i.i.d. des Parties 2-3 ne tient plus.
- On ne peut *pas* mélanger train/test au hasard.

Nouveaux outils

- **Décomposition** — séparer tendance, saisonnalité, bruit.
- **Stationnarité** — propriété qui rend la modélisation possible.
- **ARIMA, Prophet** — modèles dédiés.
- **Validation temporelle** — train = passé, test = futur.

Module 11 — Spécificités des séries temporelles

Objectifs du module 11

- Comprendre pourquoi une série temporelle ne se traite pas comme un dataset classique.
- Reconnaître les composantes d'une série : tendance, saisonnalité, cycle, bruit.
- Choisir entre décomposition additive et multiplicative.

Définition d'une série temporelle

Définition

Une suite de valeurs $\{Y_t\}_{t=1,2,\ldots,n}$ ordonnée dans le temps.

Chaque Y_t est observé à un instant t (jour, semaine, mois...).

Exemples typiques :

- Ventes journalières d'un produit.
- Trafic web horaire.
- Consommation énergétique mensuelle.
- Indicateurs financiers (cours, rendements).
- Métriques produit (DAU, MAU, conversion).

Cas pharma

Notre dataset : 8 séries temporelles journalières (les 8 catégories ATC), 2 106 jours, 2014–2019.

Le temps change tout — fuite temporelle

Erreur fatale (mais fréquente)

Utiliser `train_test_split(X, y, shuffle=True)` sur une série temporelle.

Pourquoi c'est faux :

- Mélanger les jours mélange le passé et le futur.
- Le modèle apprend à interpoler entre des dates qu'il *verra* en test.
- Performance artificiellement gonflée — fuite temporelle.
- En production, on prédit le futur à partir du passé seulement.

Règle absolue

$$\text{train} = \text{passé}, \qquad \text{test} = \text{futur}.$$

Pas de `shuffle`, jamais.

Composantes d'une série temporelle

Une série Y_t se décompose typiquement en quatre composantes.

Les quatre composantes

Tendance (T_t) Évolution lente sur le long terme (croissance, déclin).

Saisonnalité (S_t) Cycles *réguliers* de période connue (jour, semaine, an).

Cycle (C_t) Oscillations *irrégulières* de période > 1 an (cycles éco.).

Bruit (R_t) Ce qu'on ne sait pas expliquer.

En pratique pharma : tendance = croissance du fond de marché ; saisonnalité *annuelle* = R06 au printemps, R03 en automne ; saisonnalité *hebdo* = creux du dimanche ; bruit = campagnes, météo, livraisons.

Décomposition additive vs multiplicative

Deux formes selon que l'amplitude varie ou non

$$\text{Additive :} \quad Y_t = T_t + S_t + C_t + R_t$$
$$\text{Multiplicative :} \quad Y_t = T_t \cdot S_t \cdot C_t \cdot R_t$$

Comment choisir :

- **Additive** : l'amplitude des oscillations *reste constante* dans le temps.
- **Multiplicative** : l'amplitude *grandit* avec le niveau.

Astuce pratique

Si on hésite : passer en log.

$$\log(T_t \cdot S_t) = \log(T_t) + \log(S_t)$$

À retenir — Module 11

Trois réflexes avant toute analyse

1. Identifier les **composantes** attendues (tendance, saisonnalités).
2. **Visualiser** la série avant de modéliser.
3. Décider **additive ou multiplicative** (regarder si l'amplitude grandit avec le niveau).

Module 12 — Exploration et préparation

Objectifs du module 12

- Mettre une série en forme pour l'analyse.
- Maîtriser les outils `pandas` : index temporel, `resample`, `rolling`, `ewm`.
- Visualiser une série de plusieurs façons complémentaires.

Index temporel et resampling

Pratiques pandas essentielles

- Indexer par `DatetimeIndex` : `df.set_index(pd.to_datetime(df['date']))`
- Vérifier la *fréquence* : `df.index.freq`, `df.asfreq('D')`
- Ré-échantillonner : `df.resample('W').sum()`, `.mean()`, `.last()`...

Code pandas	Granularité	Cas d'usage pharma
`'D'`	jour	lecture brute, ACF/PACF
`'W'`	semaine	lissage, reporting hebdo
`'ME'`	mois	forecasting saisonnier
`'YE'`	année	tendance long terme

Valeurs manquantes dans le temps

Trois stratégies

Forward fill `ffill()` — propager la dernière valeur connue.

Interpolation linéaire `interpolate()` — relier entre les valeurs encadrantes.

Imputation saisonnière remplacer par la valeur du même jour de l'année précédente.

Attention pharma

« 0 vente » et « pharmacie fermée » ne se traitent pas pareil. Il faut un drapeau métier pour les jours fériés / fermetures, sinon on injecte du bruit dans le forecast.

Moyenne mobile (rolling)

Formule (fenêtre k)

$$\mathrm{MA}_t^{(k)} = \frac{1}{k} \sum_{i=0}^{k-1} Y_{t-i}$$

Lecture :

- Lisse les variations de courte fréquence → révèle la tendance.
- Plus k est grand, plus on lisse — au prix de la *réactivité* aux changements.
- En pandas : `df['col'].rolling(window=k).mean()`.

Choix de k

- Lisser le bruit du jour de la semaine → `rolling(7)`.
- Lisser la saisonnalité annuelle → `rolling(365)` (mais peu de points).

Moyenne mobile exponentielle (EWMA)

Formule récursive

$$\tilde{Y}_t = \alpha\, Y_t + (1-\alpha)\, \tilde{Y}_{t-1}, \quad \alpha \in (0,1]$$

Lecture :

- α proche de 1 : on suit le présent (réactif, mais bruité).
- α proche de 0 : on lisse fortement (rigide, mais lent).
- Pondération *exponentiellement décroissante* sur le passé.

Différence vs moyenne mobile classique :

- Rolling : poids *uniforme* sur les k dernières observations, 0 pour les autres.
- EWMA : poids *décroissant* sur *toutes* les observations passées.

En pandas : `df['col'].ewm(alpha=0,3).mean()` ou `ewm(span=N)`.

Visualisations utiles

Visualisation	Ce qu'elle révèle
Line plot	Tendance générale, ruptures, anomalies évidentes
Plot saisonnier	Comparaison année par année, saisonnalité reproductible
Lag plot	Auto-similarité (corrélation Y_t vs Y_{t-1})
Boxplot par mois	Saisonnalité annuelle quantifiée
Heatmap jour $\times$ semaine	Effets jour de la semaine $\times$ semaine

Cas pharma

Sur R06, le boxplot par mois met en évidence un *pic au printemps*. Le plot saisonnier montre que ce pic se reproduit chaque année.

Détection visuelle de ruptures

Trois patterns à reconnaître à l'œil

Anomalie ponctuelle Un seul point très éloigné — outlier.

Rupture de niveau La moyenne change brutalement (event business : campagne, rappel produit).

Changement de régime La variance ou la saisonnalité change (modèle de croissance, post-Covid).

Conséquence

Une rupture invalide souvent les modèles entraînés sur la période *avant*. À détecter avant de modéliser.

Module 13 — Stationnarité & autocorrélation

Objectifs du module 13

- Comprendre ce qu'est une série stationnaire et pourquoi ça compte.
- Tester la stationnarité (ADF, KPSS).
- Rendre une série stationnaire (différenciation, log).
- Lire l'ACF et la PACF.

Stationnarité — définition pratique

Stationnarité au sens faible

Une série $\{Y_t\}$ est stationnaire si :

$$\mathbb{E}[Y_t] = \mu \qquad \text{constante en } t$$

$$\mathrm{Var}(Y_t) = \sigma^2 \qquad \text{constante en } t$$

$$\mathrm{Cov}(Y_t, Y_{t+h}) = \gamma(h) \qquad \text{dépend de } h\text{, pas de } t$$

Lecture intuitive :

- Pas de tendance.
- Pas de variance qui change dans le temps.
- La structure de dépendance est la même partout.

La plupart des séries business ne sont pas stationnaires telles quelles.

Pourquoi la stationnarité compte

Le théorème implicite

Les modèles ARIMA, ARMA, et la quasi-totalité de la théorie classique des séries temporelles supposent la stationnarité de la série modélisée.

Conséquences si on l'ignore :

- Coefficients estimés *biaisés*.
- Intervalles de prédiction *faux*.
- Régressions *fallacieuses* (deux séries en tendance peuvent paraître corrélées sans lien réel).

La règle

Avant de lancer un ARIMA : **rendre la série stationnaire** (au moins approximativement).

Tests de stationnarité — ADF et KPSS

Augmented Dickey-Fuller (ADF)

- H_0 : la série *n'est pas* stationnaire (présence d'une racine unitaire).
- H_1 : la série est stationnaire.
- **p-value** $< 0{,}05 \Rightarrow$ on rejette $H_0 \Rightarrow$ la série est stationnaire.

KPSS

- H_0 : la série *est* stationnaire.
- H_1 : non stationnaire.
- **p-value** $< 0{,}05 \Rightarrow$ on rejette $H_0 \Rightarrow$ non stationnaire.

Hypothèses inversées !

ADF et KPSS testent l'hypothèse *opposée*. Les utiliser conjointement : les deux d'accord = conclusion plus fiable.

Rendre une série stationnaire

Différenciation

$$\nabla Y_t = Y_t - Y_{t-1}$$

Élimine une tendance linéaire. À répéter (d fois) si nécessaire.

Différenciation saisonnière

$$\nabla_s Y_t = Y_t - Y_{t-s}$$

avec s = période saisonnière (12 pour mensuel annuel, 7 pour hebdo).

Autres outils :

- **Log** : si la variance grandit avec le niveau.
- **Désaisonnalisation** (STL) : retirer la composante S_t.
- **Box-Cox** : transformation paramétrée pour stabiliser la variance.

Autocorrélation — ACF et PACF

ACF — fonction d'autocorrélation

$$\rho(h) = \frac{\mathrm{Cov}(Y_t,\ Y_{t+h})}{\mathrm{Var}(Y_t)}$$

Corrélation entre la série et elle-même décalée de h pas.

PACF — autocorrélation partielle

Corrélation entre Y_t et Y_{t-h} après avoir retiré l'effet des lags intermédiaires $Y_{t-1}, \ldots, Y_{t-h+1}$.

Pourquoi deux courbes :

- L'ACF capte *toute* la dépendance, y compris indirecte.
- La PACF isole la dépendance *directe* à chaque lag.

Lecture pratique de l'ACF/PACF

Pattern observé	Interprétation	Modèle indiqué
ACF décroît lentement	Tendance / non stationnaire	Différencier d'abord
Pics ACF aux lags multiples de s	Saisonnalité de période s	SARIMA (P, D, Q, s)
PACF coupe à p, ACF décroît	Auto-régressif d'ordre p	AR(p) ou ARIMA$(p, d, 0)$
ACF coupe à q, PACF décroît	Moyenne mobile d'ordre q	MA(q) ou ARIMA$(0, d, q)$
Les deux décroissent	Mixte ARMA	ARIMA(p, d, q)

En pratique

On lit l'ACF/PACF sur la *série différenciée* (stationnaire). Pour `auto_arima`, on laisse choisir l'algo mais on confirme à l'œil.

À retenir — Module 13

Workflow standard avant ARIMA

1. Visualiser la série brute.
2. Tester la stationnarité (ADF + KPSS).
3. Si non stationnaire : différencier ($d = 1$, parfois $D = 1$ pour la saison).
4. Re-tester la stationnarité.
5. Lire l'ACF/PACF de la série stationnaire pour identifier (p, q) et (P, Q).

Module 14 — Modèles de prévision

Objectifs du module 14

- Connaître les modèles courants : baselines, lissage exponentiel, ARIMA / SARIMA, Prophet.
- Savoir lequel essayer en premier selon le contexte.
- Évaluer un forecast en validation temporelle.
- Lire un intervalle de prédiction.

Toujours commencer par les baselines

Trois baselines à *toujours* tester

Naïve $\hat{Y}_{t+1} = Y_t$ (la dernière valeur observée).

Naïve saisonnière $\hat{Y}_{t+1} = Y_{t+1-s}$ (la valeur du même point l'an passé).

Moyenne historique $\hat{Y}_{t+1} = \bar{Y}$.

Règle absolue

Tout modèle complexe (SARIMA, Prophet, LSTM) qui *ne bat pas* la naïve saisonnière sur des données saisonnières n'apporte rien.

Sur des séries pharma à forte saisonnalité annuelle, la naïve saisonnière est étonnamment performante.

Lissage exponentiel simple (SES)

Formule

$$\tilde{Y}_t = \alpha\, Y_t + (1-\alpha)\, \tilde{Y}_{t-1}$$

Prévision : $\hat{Y}_{t+h} = \tilde{Y}_t$ (constante en h).

Quand l'utiliser :

- Série *sans tendance* ni saisonnalité.
- Quand on veut un benchmark simple, robuste.

Limite

Ne capture ni la tendance, ni la saisonnalité $\rightarrow$ inadapté à la plupart des séries pharma. Mais utile comme baseline supplémentaire.

Holt et Holt-Winters

Holt — niveau + tendance

$$\ell_t = \alpha\, Y_t + (1-\alpha)(\ell_{t-1} + b_{t-1})$$
$$b_t = \beta\,(\ell_t - \ell_{t-1}) + (1-\beta)\, b_{t-1}, \quad \hat{Y}_{t+h} = \ell_t + h\, b_t$$

Holt-Winters — niveau + tendance + saisonnalité

Ajoute un troisième composant s_t (constante de lissage γ). Versions *additive* ou *multiplicative* (selon la décomposition).

Quand l'utiliser : série avec saisonnalité claire et peu de données. Très *rapide* à entraîner, simple à expliquer.

ARIMA (p, d, q)

Formulation

Sur la série *différenciée d fois* (stationnaire) :

$$\nabla^d Y_t = c + \underbrace{\sum_{i=1}^{p} \phi_i \, \nabla^d Y_{t-i}}_{\text{AR}(p)} + \underbrace{\sum_{j=1}^{q} \theta_j \, \varepsilon_{t-j}}_{\text{MA}(q)} + \varepsilon_t$$

Lecture des trois paramètres :

- p : nombre de lags auto-régressifs (AR).
- d : nombre de différenciations (I).
- q : nombre de termes de moyenne mobile (MA).

Choix guidé par l'ACF/PACF (M13) ou `pmdarima.auto_arima`.

SARIMA $(p, d, q)(P, D, Q, s)$

Idée

ARIMA + une composante saisonnière avec sa propre période s.

Six paramètres :

- (p, d, q) : composante non saisonnière (cf. ARIMA).
- (P, D, Q, s) : composante saisonnière, s = période (12 pour mensuel annuel, 7 pour hebdo).

Cas pharma — R06 mensuel

SARIMA$(1, 1, 1)(1, 1, 1, 12)$: différenciation simple + différenciation saisonnière annuelle, plus 1 lag AR/MA dans chaque composante. Bon point de départ.

Limite : ne capte pas facilement les variables externes (jours fériés, campagnes). → Prophet.

Prophet (Meta) — modèle additif générique

Décomposition

$$Y_t = g(t) + s(t) + h(t) + \varepsilon_t$$

- $g(t)$: tendance (linéaire ou logistique avec saturation).
- $s(t)$: saisonnalités multiples (annuelle, hebdo, journalière) en séries de Fourier.
- $h(t)$: effets des jours fériés / événements ; ε_t : bruit.

Pourquoi Prophet est pratique pour un analyst :

- Gestion native des *jours fériés* ; saisonnalités *multiples* sans tuning.
- Tendance *changeante* (changepoints) automatique.
- Robuste aux valeurs manquantes et aux outliers.

SARIMA vs Prophet — quand choisir lequel

Critère	SARIMA	Prophet
Saisonnalité multiple	1 seule (paramètre s)	Multiples natives
Jours fériés / événements	Manuels (SARIMAX exogènes)	Natives, riches
Tendance changeante	Non (1 seule différenciation)	Changepoints auto
Ajustement	Tuning ou `auto_arima`	Très peu de tuning
Données manquantes	Sensibles	Robustes
Petites séries	Bon	Moins précis
Séries très volatiles	Capable mais difficile	Limites visibles

Conseil pratique

Sur une série pharma standard : **tester les deux**, choisir celui qui bat le mieux la naïve saisonnière en backtesting.

Mention — approches modernes

Quand y penser

XGBoost / LightGBM sur features de lag Quand on a beaucoup de variables externes (météo, prix, marketing). Demande du feature engineering.

LSTM, GRU Réseaux récurrents. Bons pour des dépendances longues, mais demandent beaucoup de données.

N-BEATS, Temporal Fusion Transformer État de l'art récent. Très puissants, mais complexes à mettre en production.

Quand ne PAS y aller

- Peu de données (< 5 saisons complètes).
- Pas d'équipe pour maintenir un modèle DL en production.
- SARIMA / Prophet font déjà le job.

Évaluation — la validation temporelle

Règle absolue

Train = passé, Test = futur. Toujours.

Backtesting (rolling origin)

On simule plusieurs « instants de prédiction » :

- Itération 1 : train $= [1, T_1]$, prédire $[T_1 + 1, T_1 + h]$.
- Itération 2 : train $= [1, T_2]$, prédire $[T_2 + 1, T_2 + h]$.
- ...et ainsi de suite.

On agrège les erreurs sur toutes les itérations.

Pourquoi c'est plus fiable qu'un seul split : évite la chance d'avoir choisi un test « facile ».

Métriques d'évaluation

Quatre métriques classiques

$$\mathrm{MAE} = \frac{1}{n}\sum_{t=1}^{n} |Y_t - \hat{Y}_t|$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t=1}^{n} (Y_t - \hat{Y}_t)^2}$$

$$\mathrm{MAPE} = \frac{100}{n}\sum_{t=1}^{n} \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right|$$

$$\mathrm{sMAPE} = \frac{100}{n}\sum_{t=1}^{n} \frac{2\,|Y_t - \hat{Y}_t|}{|Y_t| + |\hat{Y}_t|}$$

Quelle métrique choisir ?

Métrique	Avantage	Limite
MAE	Robuste aux outliers, même unité que Y	N'amplifie pas les grosses erreurs
RMSE	Pénalise plus les grosses erreurs	Sensible aux outliers
MAPE	Sans unité, comparable entre séries	Explose près de 0, asymétrique
sMAPE	Symétrique, sans unité, borné	Moins intuitive que MAPE

Piège pharma

Sur N05C (catégorie qui contient beaucoup de zéros), la **MAPE** explose. Préférer **MAE** ou **sMAPE**.

Intervalles de prédiction

Différence avec l'intervalle de confiance

- **IC (M6)** : incertitude sur un *paramètre* (ex : la moyenne).
- **Intervalle de prédiction** : incertitude sur une *observation future*.

L'intervalle de prédiction est *toujours plus large* que l'IC sur la moyenne.

Pourquoi c'est essentiel :

- Une prédiction ponctuelle « 1 200 unités le mois prochain » est presque sûrement fausse.
- Un intervalle « entre 950 et 1 450 avec 80 % de confiance » est défendable et exploitable.
- Pour le stock de sécurité, c'est l'intervalle qui compte, pas le point.

C'est l'analogue temporel des **quantiles** de loi vus en M5.

À retenir — Module 14

Pipeline d'un forecast en pharma

1. **Visualiser** la série, identifier composantes & ruptures.
2. **Stationnariser** si besoin (différenciation, log).
3. **Baselines** : naïve, naïve saisonnière, moyenne.
4. **Modèles** : SARIMA et/ou Prophet.
5. **Backtesting** avec rolling origin.
6. **Métriques** adaptées (MAE/sMAPE plutôt que MAPE).
7. **Reporter** la prédiction *avec son intervalle*.

Module 15 — Détection d'anomalies

Objectifs du module 15

- Savoir signaler une anomalie sur une série temporelle.
- Connaître plusieurs approches du plus simple au plus avancé.
- Communiquer une anomalie au métier de façon actionnable.

Approches simples — z-score sur fenêtre roulante

Méthode

$$z_t = \frac{Y_t - \mu_t^{(k)}}{\sigma_t^{(k)}}$$

où $\mu_t^{(k)}$ et $\sigma_t^{(k)}$ sont la moyenne et l'écart-type calculés sur la *fenêtre* des k derniers points.

Règle de décision :

- $|z_t| > 3$: anomalie.
- $|z_t| > 2$: à surveiller.

Limite

Sur une série *saisonnière*, le z-score classique signale tous les pics saisonniers comme anomalies. Solution : appliquer la méthode aux *résidus* de la décomposition.

STL decomposition + détection sur résidus

Pipeline en trois étapes

1. **Décomposer** la série : $Y_t = T_t + S_t + R_t$ (STL).
2. **Calculer** le z-score sur les *résidus* R_t uniquement.
3. **Signaler** les points avec $|z_t^R| > 3$ comme anomalies.

Pourquoi ça marche :

- La saisonnalité et la tendance, qui sont *attendues*, sont retirées.
- Reste le signal *inattendu* — c'est lui qui révèle les vraies anomalies.

Cas pharma

Un pic de N02BE en mai (hors saison) qui ressort dans les résidus = potentiellement un événement (rappel produit chez le concurrent, épidémie locale).

Approches avancées (mention)

Trois familles

Isolation Forest Détecte les points « faciles à isoler » dans l'espace des features. Bon en multivarié.

Prophet residuals Prophet renvoie un intervalle de prédiction. Ce qui sort = anomalie.

SARIMA residuals Idem avec ARIMA — z-score sur les résidus du modèle ajusté.

Choix selon le contexte :

- Multivarié, peu de structure temporelle $\rightarrow$ Isolation Forest.
- Saisonnalité claire, peu de données $\rightarrow$ STL + z-score.
- Forecast déjà en place $\rightarrow$ utiliser les résidus du modèle existant.

Communiquer une anomalie au métier

Une bonne alerte contient

1. **Quoi** : variable + date.
2. **Combien** : valeur observée vs valeur attendue (avec intervalle).
3. **Sévérité** : z-score, ou « 3σ », ou « top 1 % des écarts ».
4. **Contexte** : événements connus (jour férié, livraison ratée…).
5. **Action proposée** : « à investiguer », « stock à ajuster », « pas d'action ».

Faux positifs

Un système trop sensible désensibilise les utilisateurs. Mieux vaut quelques alertes pertinentes que beaucoup de bruit.

À retenir — Module 15

Trois questions avant de signaler

1. L'écart est-il vraiment *anormal* (vs juste un pic saisonnier) ?
2. L'écart est-il *actionnable* ? (sinon, ne pas alerter)
3. Le coût d'une fausse alerte vs d'un faux négatif justifie-t-il le seuil retenu ?

Synthèse de la partie 4

Ce que vous savez faire à la fin de la partie 4

- Identifier les composantes d'une série (tendance, saisonnalité, cycle, bruit).
- Préparer une série : index temporel, resampling, valeurs manquantes, lissage.
- Tester la **stationnarité** (ADF, KPSS) et stationnariser (différenciation, log).
- Lire l'**ACF/PACF** pour orienter le choix de modèle.
- Construire des baselines, ajuster un **SARIMA** et un **Prophet**, valider en split temporel.
- Choisir la métrique adaptée (MAE, RMSE, MAPE, sMAPE) et leurs limites.
- **Détecter et communiquer** une anomalie de manière actionnable.

Suite de la formation

Partie 5 — Synthèse & bonnes pratiques (M16-M17)

- Module 16 : adapter la communication des résultats au public (technique vs business).
- Module 17 : arbre de décision global « quel outil pour quelle question ».

Liens explicites avec la suite

- Communication des intervalles de prédiction (M14) — *showstopper* pour le management.
- Anomalies (M15) — formats d'alerte au métier.

Questions ?

Pause avant la synthèse

Bassem Ben Hamed — bassem.benhamed@enetcom.usf.tn