De la donnée à la décision

Statistiques pour les Experts Data

Partie 5 — Synthèse & bonnes pratiques

Modules 16 et 17

Bassem Ben Hamed

bassem.benhamed@enetcom.usf.tn

Formation interne

Plan de la partie 5

Module 16 — Communiquer ses résultats

Module 17 — Récapitulatif & arbre de décision global

Où en sommes-nous ?

Architecture de la formation (5 parties, 17 modules)

Partie	Modules
1. Descriptive	M0 Introduction, M1 Décrire, M2 Visualiser, M3 Relations
2. Probabilités	M4 Vocabulaire probabiliste, M5 Lois usuelles
3. Inférentielle	M6 Échantillon → population, M7 Tests, M8 Choisir le bon test, M9 Régression linéaire, M10 Régression logistique
4. Séries temporelles	M11 Spécificités, M12 Préparation, M13 Stationnarité & ACF, M14 SARIMA & Prophet, M15 Anomalies
5. Synthèse	**M16 Communication, M17 Récapitulatif & arbre de décision**

La dernière marche — celle qui fait la différence

Une analyse correcte mais mal communiquée n'a aucun impact. Cette partie transforme votre travail technique en *décision business*.

Ce qu'on a vu jusqu'ici, en une slide

Outils maîtrisés

- Statistiques descriptives & visualisations.
- Lois de probabilité (discrètes, continues).
- Intervalles de confiance, tests d'hypothèse.
- Régression linéaire, logistique.
- ARIMA / SARIMA, Prophet.
- Détection d'anomalies.

Réflexes acquis

- Toujours regarder ses données avant de modéliser.
- Vérifier les hypothèses des tests / modèles.
- Donner une marge d'erreur, pas juste un point.
- Valider en *split temporel* sur les séries.
- Comparer à une baseline simple.

Ce qui manque

Tout cela ne sert à rien si la décision finale ne change pas. C'est l'objet de cette dernière partie.

Module 16 — Communiquer ses résultats

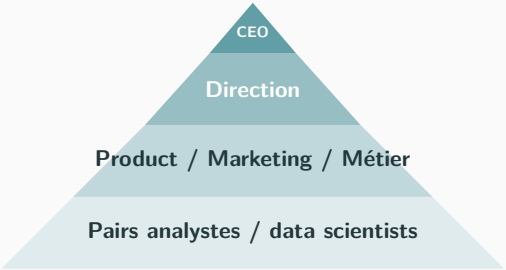
Objectifs du module 16

- Adapter le **niveau de détail** au public visé (technique vs business).
- **Communiquer l'incertitude** (IC, intervalles de prédiction) sans noyer le décideur.
- Distinguer les visualisations **qui trompent** de celles qui **éclairent**.
- Disposer d'une **checklist** de pré-livraison.

Postulat

Le métier d'analyste ne s'arrête pas au notebook. La moitié de la valeur est livrée après les résultats.

La pyramide des audiences



Règle d'or

Plus on monte, plus on synthétise. Le détail ne disparaît pas — il devient un *annexe*, pas le *titre*.

Adapter le langage — exemple concret

Pour des pairs (notebook / revue technique)

« On rejette H_0 au seuil $\alpha = 0{,}05$: $t = 3{,}21$, $\mathrm{ddl} = 102$, $p = 0{,}0017$. La taille d'effet (Cohen's d) est de 0,45, donc effet modéré. »

Pour le métier (réunion produit)

« Les ventes du week-end sont en moyenne 12 % plus élevées qu'en semaine. Cet écart est robuste : on a moins d'1 chance sur 500 qu'il soit dû au hasard. »

Pour la direction (slide unique)

« Renforcer le staffing du week-end : +12 % de ventes systématique vs semaine. »

Communiquer l'incertitude

Trois niveaux acceptables :

1. **Une fourchette**
   « entre 1 200 et 1 450 ventes »
2. **Une fourchette + niveau de confiance**
   « 1 200–1 450 (IC à 95%) »
3. **Un graphique avec bande de prédiction**

Ce qu'il faut éviter :

- Donner uniquement la moyenne (« 1 325 ventes »).
- Cacher l'incertitude derrière un chiffre rond.

Le piège du chiffre unique

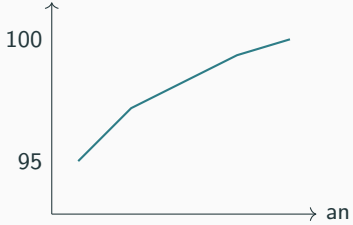
Un chiffre seul donne une fausse précision. Le décideur prend une décision *trop tranchée* — surtout sur les forecasts.

En pratique

Pour le *stock de sécurité*, ce n'est pas la prédiction qui compte, c'est la borne supérieure de l'IC.

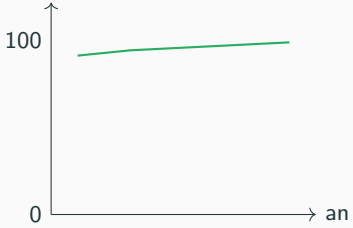
Visualisations qui trompent (1/2) — l'axe Y

Axe Y tronqué (départ $\neq 0$)



« hausse spectaculaire »

Axe Y depuis 0



« presque plate »

Règle pratique

Pour les barres : l'axe Y doit démarrer à 0. *Pour les courbes temporelles :* acceptable de tronquer si on l'indique clairement.

Visualisations qui trompent (2/2)

Pièges visuels classiques

- **3D et effets gadget** — déforment les proportions.
- **Camembert à 8+ parts** — illisible : préférer un bar chart trié.
- **Échelles différentes superposées** sans double-axe explicite.
- **Couleurs trompeuses** (rouge = mal, vert = bien) sans légende.
- **Cherry-picking** de la fenêtre temporelle.

Pièges visuels à éviter

- Une **idée par graphique**.
- **Titrer** le graphique avec sa *conclusion*, pas son contenu.
- Annoter les **points clés** directement.
- Une **palette accessible** (daltoniens : éviter rouge/vert seuls).
- Donner les **unités** et la **source**.

Le titre du graphique = sa conclusion

Avant — titre descriptif

« Ventes mensuelles de R06 par année »

Après — titre conclusif

« Les ventes de R06 doublent chaque printemps (avril–mai) »

Pourquoi

Le décideur lit le titre en 2 secondes. S'il ne s'arrête que là, il doit déjà avoir le *message clé*. Le graphique sert ensuite à *prouver*.

Storytelling data en 4 actes

1. **Contexte** — pourquoi cette analyse, qui en a besoin, quelle décision est en jeu.
2. **Tension** — ce qu'on *croyait* vs ce que les données *montrent*.
3. **Résolution** — les chiffres clés (3 max) avec leur incertitude.
4. **Action** — une recommandation actionnable, une seule.

Test du « So what ? »

Après chaque slide, demandez-vous : *si on s'arrête ici, le décideur sait-il ce qu'il doit faire ?* Si la réponse est non, la slide est superflue.

Vérifier ses hypothèses — checklist par famille

Famille	Hypothèses critiques	Comment vérifier
Test t / ANOVA	Normalité, égalité des variances	QQ-plot, Shapiro, Levene
Régression linéaire	Linéarité, homoscédasticité, indép. des résidus	Plots résidus, Durbin-Watson
Régression logistique	Pas de séparation parfaite, indép. obs.	Tableau croisé cible / features
SARIMA	Stationnarité après diff., résidus = bruit blanc	ADF, Ljung-Box sur résidus
Prophet	Saisonnalités stables, peu de ruptures de tendance	Plots de composantes

Si une hypothèse échoue

Trois options : (1) transformer les données (log, diff), (2) changer de méthode (Mann-Whitney au lieu de t), (3) reporter le résultat en signalant explicitement la limite.

Tester la robustesse de ses résultats

Trois questions à se poser avant de livrer

1. **Le résultat tient-il si je retire 5 % des observations** (au hasard, ou les plus extrêmes) ?
2. **Le résultat change-t-il si je change la fenêtre temporelle** (ex : retirer 2020 / la covid) ?
3. **Le résultat tient-il avec une méthode alternative** (régression robuste, test non paramétrique) ?

Si oui aux trois

Le résultat est *robuste*. On peut le présenter avec confiance.

Si non à au moins une

Mentionner explicitement la *sensibilité* dans le rapport. Mieux vaut un résultat nuancé qu'un résultat faux.

Déclarer ses limites — un signe de sérieux

Un bon rapport finit toujours par une section « Limites » :

- **Limites des données** : taille d'échantillon, biais de sélection, période, valeurs manquantes traitées.
- **Limites du modèle** : hypothèses non vérifiées, capacité de généralisation.
- **Limites de l'interprétation** : corrélation $\neq$ causalité, fenêtre temporelle particulière.
- **Ce qu'on n'a *pas* testé** : effets confondants potentiels, sous-groupes non analysés.

Le paradoxe de la confiance

Un analyste qui mentionne ses limites est plus crédible que celui qui n'en mentionne aucune. Le métier comprend qu'il a fait l'effort de vérifier.

Format type d'un livrable

Section	Contenu
TL ;DR (1 slide)	Question business + chiffre clé + recommandation.
Contexte	Pourquoi cette analyse, qui la commande, quelle décision en dépend.
Données	Source, période, granularité, traitement des manquants, n.
Méthode	Choix des outils en 5 lignes (sans démonstration).
Résultats	3 chiffres clés *avec leur intervalle*, 1–3 graphiques annotés.
Robustesse	Tests de sensibilité réalisés, conclusions.
Limites	Explicites, listées, non cachées.
Recommandation	1–3 actions concrètes, priorisées.
Annexes	Code, détails techniques, tests intermédiaires.

Slide / notebook / dashboard — quel format ?

Format	Quand l'utiliser	Forces	Limites
Slides PDF	Décision ponctuelle, comité	Synthèse forcée, offline	Statique, vite obsolète
Notebook	Revue technique entre analystes	Reproductible, code visible	Trop lourd pour métier
Dashboard	Suivi récurrent (KPI, monitoring)	Toujours à jour, libre-service	Demande maintenance
Email / Slack	Alerte ponctuelle, anomalie	Rapide, bonne personne	Pas archivable proprement
Note / 1-pager	Synthèse exécutive d'analyse	Auto-portant, partageable	Effort rédactionnel

Choisir selon le *rythme*

Décision unique → slides ou note. *Question récurrente* → dashboard. *Investigation* → notebook + 1-pager final.

Checklist pré-livraison (à imprimer)

Avant de cliquer « envoyer »

- ☐ La **question business** est-elle posée explicitement en début de doc ?
- ☐ Les **hypothèses du modèle** ont-elles été vérifiées ?
- ☐ Chaque résultat a-t-il son **intervalle / sa marge d'erreur** ?
- ☐ Les graphiques ont-ils des **titres conclusifs**, des unités, une source ?
- ☐ Ai-je **testé la robustesse** (échantillon, fenêtre, méthode alternative) ?
- ☐ Les **limites** sont-elles déclarées explicitement ?
- ☐ Y a-t-il **une recommandation actionnable** ?
- ☐ Le **TL ;DR** tient-il en 30 secondes de lecture ?
- ☐ Le **format** est-il adapté au public ?
- ☐ Quelqu'un d'autre que moi a-t-il **relu** ?

Anti-patterns fréquents (à fuir)

Erreurs récurrentes en communication data

- **« J'ai trouvé un truc intéressant »** — sans contextualiser la décision.
- **Le « graphique-poubelle »** — 12 courbes, 3 légendes, 0 message.
- **La p-value seule** — « $p = 0{,}03$ » sans taille d'effet ni intervalle.
- **Le copier-coller de notebook** — code brut envoyé au métier.
- **Le forecast sans incertitude** — un chiffre rond, prétention de précision.
- **La conclusion noyée** — message clé page 14 d'un PDF de 20 pages.
- **Le « corrélation = causalité » caché** — « A explique B » alors qu'on n'a fait qu'une corrélation.

Synthèse du module 16

- Le *travail technique* ne fait que la moitié du chemin. La communication fait l'autre moitié.
- **Adapter** le niveau de détail au public.
- **Toujours communiquer l'incertitude** — un chiffre seul est trompeur.
- **Titre conclusif** sur les graphiques.
- **Checklist** avant livraison.
- **Déclarer les limites** explicitement — ça renforce la crédibilité.

Module 17 — Récapitulatif & arbre de décision global

Objectifs du module 17

- Disposer d'un **arbre de décision** « quel outil pour quelle question ».
- Connaître les **pièges récurrents** de chaque famille.
- Avoir une **cheatsheet** prête à l'emploi (formules & code).
- Identifier les **ressources** pour aller plus loin.

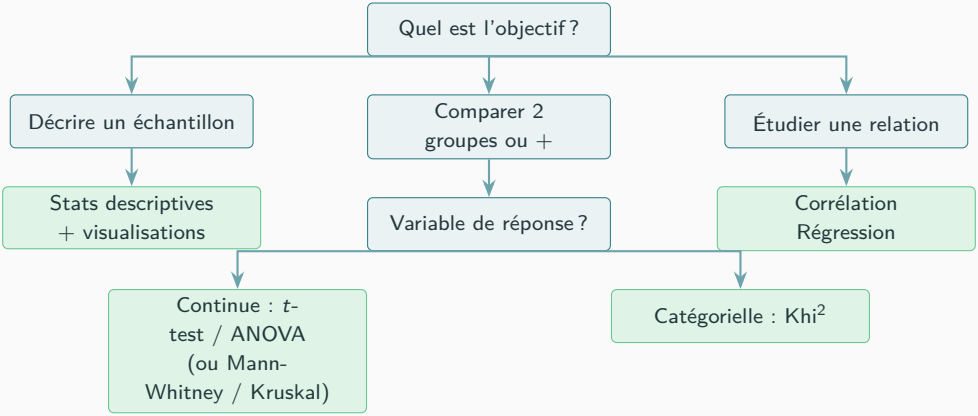
Format

Cette partie est volontairement *tabulaire et synthétique*. C'est la fiche à garder sous les yeux quand on attaque une nouvelle analyse.

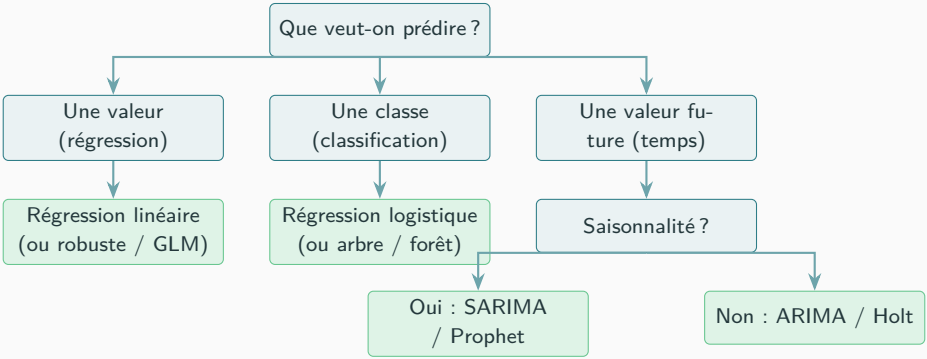
Quel outil pour quelle question — vue d'ensemble

Question business	Outil(s)
« À quoi ressemblent mes données ? »	Stats descriptives, visualisations (M1–M3)
« Quelle loi modélise mon phénomène ? »	Lois usuelles + ajustement empirique (M5)
« Y a-t-il une différence entre 2 groupes ? »	Test d'hypothèse adapté (M7–M8)
« Y a-t-il une différence entre 3+ groupes ? »	ANOVA / Kruskal-Wallis (M8)
« Quelles variables expliquent X ? »	Corrélation, régression linéaire/logistique (M9–M10)
« Quelle est la marge d'erreur de mon estimation ? »	Intervalle de confiance (M6)
« Combien va-t-on vendre le mois prochain ? »	Modèle de série temporelle (M11–M14)
« Cette valeur est-elle anormale ? »	Détection d'anomalies (M15)

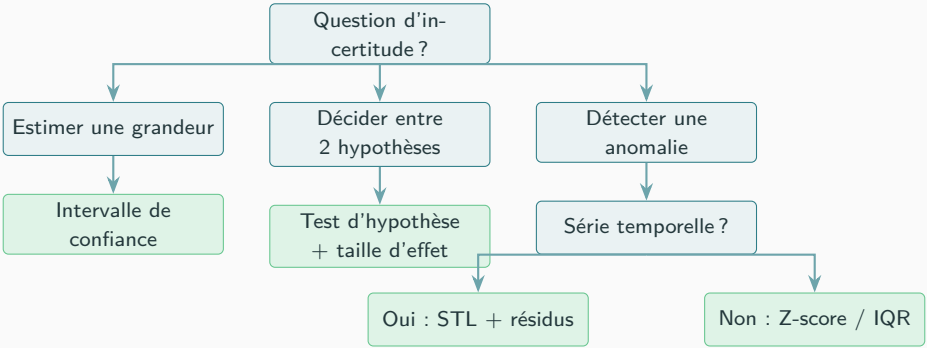
Arbre de décision — partie 1 : décrire / comparer



Arbre de décision — partie 2 : prédire / temps



Arbre de décision — partie 3 : incertitude / anomalies



Pièges récurrents — Partie 1 (Descriptive)

Erreurs classiques

- Confondre **moyenne et médiane** sur une distribution asymétrique.
- Comparer des écarts-types sans **coefficient de variation**.
- Tirer des conclusions causales d'une simple **corrélation**.
- Oublier les **valeurs aberrantes** avant de calculer une moyenne.

Bons réflexes

- Toujours **regarder** les données (histogramme, boxplot).
- Médiane + IQR si distribution asymétrique.
- **Spearman** si la relation n'est pas linéaire.

Pièges récurrents — Partie 2 (Probabilités)

Erreurs classiques

- Appliquer la **loi normale** à des comptages d'événements rares (préférer Poisson).
- Confondre **indépendance** et **exclusion mutuelle** pour deux événements.
- Mal interpréter une **probabilité conditionnelle** ($P(A|B) \neq P(B|A)$).
- Utiliser une loi sans vérifier visuellement l'**ajustement empirique**.

Bons réflexes

- Histogramme + densité théorique **superposés** avant de croire à une loi.
- Tableau de **Bayes** pour les probabilités conditionnelles.
- Connaître les 5 lois clés (binomiale, Poisson, normale, exponentielle, uniforme).

Pièges récurrents — Partie 3 (Inférentielle)

Erreurs classiques

- **p-value seule** sans taille d'effet ni intervalle de confiance.
- **p-hacking** : multiplier les tests jusqu'à en trouver un significatif.
- Confondre **significatif statistiquement** et **important en pratique**.
- Régression sans vérifier les **résidus** (homoscédasticité, normalité).
- R^2 **élevé** = bon modèle ? Pas toujours (overfitting, multicolinéarité).

Bons réflexes

- **Pré-enregistrer** ses hypothèses avant de regarder les données.
- Reporter *p-value* + *taille d'effet* + *IC*.
- Correction de Bonferroni si tests multiples ; validation croisée pour la régression.

Pièges récurrents — Partie 4 (Séries temporelles)

Erreurs classiques

- **Train/test aléatoire** sur une série temporelle (fuite du futur).
- Modéliser une série **non stationnaire** sans la différencier.
- Croire un modèle parce qu'il « fitte bien le passé » (overfit).
- Oublier de comparer à une **baseline naïve saisonnière**.
- **MAPE seule** alors qu'on a des valeurs proches de 0 ; **prédiction ponctuelle** sans intervalle.

Bons réflexes

- Split temporel + **rolling origin** pour valider ; **tests ADF / KPSS** avant ARIMA.
- Plusieurs métriques (MAE, RMSE, sMAPE).
- Toujours un **intervalle de prédiction**.

Cheatsheet — formules essentielles (1/2)

Concept	Formule
Moyenne / variance	$\bar{x} = (1/n)\sum x_i \quad ; \quad s^2 = (1/(n-1))\sum (x_i - \bar{x})^2$
Coefficient de variation	$\mathrm{CV} = s/\bar{x}$
Corrélation (Pearson)	$r = \mathrm{Cov}(X, Y)/(s_X s_Y)$
Loi binomiale	$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$
Loi de Poisson	$P(X = k) = e^{-\lambda}\lambda^k / k!$
Loi normale	$f(x) = (1/(\sigma\sqrt{2\pi}))\exp(-(x-\mu)^2/(2\sigma^2))$
Loi exponentielle	$f(x) = \lambda e^{-\lambda x}$, $x \geq 0$
Bayes	$P(A\|B) = P(B\|A)P(A)/P(B)$
IC sur moyenne (σ inconnu)	$\bar{x} \pm t_{n-1,1-\alpha/2} \cdot s/\sqrt{n}$
Statistique t (2 échantillons)	$t = (\bar{x}_1 - \bar{x}_2)/\sqrt{s_1^2/n_1 + s_2^2/n_2}$
Khi^2 (indépendance)	$\chi^2 = \sum (O_{ij} - E_{ij})^2 / E_{ij}$

Cheatsheet — formules essentielles (2/2)

Concept	Formule
Régression linéaire	$\hat{Y} = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$
R^2	$1 - \mathrm{SSR}/\mathrm{SST}$
Régression logistique	$\log(p/(1-p)) = \beta_0 + \sum \beta_j X_j$
Odds ratio	$\mathrm{OR} = e^{\beta_j}$
Décomposition additive	$Y_t = T_t + S_t + R_t$
Différenciation	$\nabla Y_t = Y_t - Y_{t-1}$
Différenciation saisonnière	$\nabla_s Y_t = Y_t - Y_{t-s}$
Naïve saisonnière	$\hat{Y}_{t+1} = Y_{t+1-s}$
SARIMA	$(p, d, q)(P, D, Q, s)$
Prophet	$Y_t = g(t) + s(t) + h(t) + \varepsilon_t$
MAE / RMSE	$(1/n)\sum \lvert e_t \rvert$; $\sqrt{(1/n)\sum e_t^2}$
sMAPE	$(100/n)\sum 2\lvert e_t \rvert / (\lvert Y_t \rvert + \lvert \hat{Y}_t \rvert)$

Cheatsheet — code Python prêt à l'emploi (1/2)

Statistiques descriptives

```
df.describe()                    # résumé numérique
df.corr(method='pearson')        # corrélations
df.boxplot(by='groupe')          # distribution par groupe
```

Probabilités (scipy.stats)

```
from scipy import stats
stats.norm(mu, sigma).cdf(x)     # P(X <= x)
stats.poisson(lam).pmf(k)        # P(X = k)
stats.norm.fit(data)             # ajuster une loi
```

Tests (scipy.stats)

```
stats.ttest_ind(g1, g2)          # t-test 2 echantillons
stats.f_oneway(g1, g2, g3)       # ANOVA
stats.chi2_contingency(table)    # khi2 d'independance
stats.mannwhitneyu(g1, g2)       # alternative non-param.
```

Cheatsheet — code Python prêt à l'emploi (2/2)

Régression (statsmodels / sklearn)

```
import statsmodels.formula.api as smf
m = smf.ols('y ~ x1 + x2 + C(group)', data=df).fit()
print(m.summary())                  # coefs, p, R2

m_log = smf.logit('y ~ x1 + x2', data=df).fit()
```

Séries temporelles

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
m = SARIMAX(y, order=(1,1,1), seasonal_order=(1,1,1,12)).fit()
fcst = m.get_forecast(steps=12); ci = fcst.conf_int()

import pmdarima as pm
auto = pm.auto_arima(y, m=12, seasonal=True)

from prophet import Prophet
p = Prophet(yearly_seasonality=True).fit(df_p)
```

Pour aller plus loin

Lectures recommandées

- **R. Hyndman, G. Athanasopoulos** — *Forecasting : Principles and Practice* (gratuit en ligne, référence séries temporelles).
- **T. Hastie, R. Tibshirani** — *An Introduction to Statistical Learning* (gratuit, ML statistique).
- **C. Wickham** — *Storytelling with Data* (communication).
- **N. Silver** — *The Signal and the Noise* (incertitude, prévision).

Datasets pour s'exercer

- **Kaggle** — datasets variés (retail, énergie, santé).
- **UCI Machine Learning Repository**.
- **INSEE / Eurostat** — séries temporelles macro-économiques.
- **Google Trends** — séries comportementales.

Les 10 commandements du data analyst

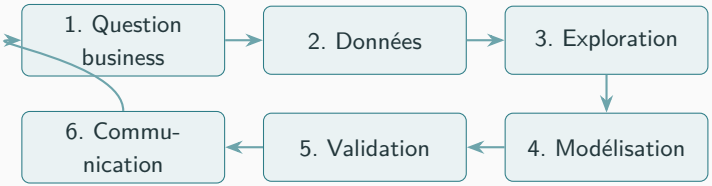
1. Tu **regarderas** tes données avant de modéliser.
2. Tu **vérifieras les hypothèses** de tes tests et modèles.
3. Tu **donneras une marge d'erreur**, pas un chiffre seul.
4. Tu **compareras à une baseline** avant de te féliciter.
5. Tu ne **confondras pas** corrélation et causalité.
6. Tu **ne testeras pas en boucle** jusqu'à trouver ce qui t'arrange.
7. Tu **valideras en split temporel** sur les séries.
8. Tu **titreras tes graphiques avec leur conclusion**.
9. Tu **déclareras tes limites** — c'est un signe de sérieux.
10. Tu **produiras une recommandation actionnable** — sinon, à quoi bon ?

Conclusion générale

Récapitulatif des 5 parties

Partie	Question principale	Outils principaux
1. Descriptive	À quoi ressemblent mes données ?	Moyenne, médiane, IQR, histogramme, boxplot, corrélation
2. Probabilités	Quel modèle aléatoire colle ?	Lois binomiale, Poisson, normale, exponentielle, Bayes
3. Inférentielle	Que puis-je conclure malgré l'aléa ?	IC, tests t / χ^2 / ANOVA, régression linéaire & logistique
4. Séries temporelles	Comment évoluent les données dans le temps ?	STL, ACF/PACF, SARIMA, Prophet, anomalies
5. Synthèse	Comment transformer ça en décision ?	Communication, arbre de décision, checklist

Le cycle complet d'une analyse



Tout est itératif

Aucune étape n'est un aller simple. Une découverte en *exploration* peut faire reformuler la *question*. La *validation* peut faire revoir le *modèle*.

Ce que vous savez faire à la fin de la formation

- **Décrire** un dataset (centre, dispersion, forme, relations).
- **Modéliser** un phénomène aléatoire avec une loi de probabilité.
- **Estimer** une grandeur avec son intervalle de confiance.
- **Tester** une hypothèse et choisir le bon test selon la situation.
- **Expliquer / prédire** avec une régression linéaire ou logistique.
- **Décomposer et stationnariser** une série temporelle.
- **Prévoir** avec SARIMA et Prophet, et comparer à des baselines.
- **Détecter** une anomalie de manière actionnable.
- **Communiquer** vos résultats au bon niveau de détail.
- **Choisir** le bon outil pour chaque question (arbre de décision).

Mot de la fin

« Un *bon* data analyst ne cherche pas à prouver qu'il a raison. Il cherche à aider une décision. »

Les outils statistiques ne sont *qu'un moyen*.
Le but reste : *transformer la donnée en décision plus éclairée*.

Merci !

Questions ? Discussion ?

Bassem Ben Hamed — bassem.benhamed@enetcom.usf.tn